DETEKSI JERAWAT (*ACNE VULGARIS*) MENGGUNAKAN ALGORITMA YOLOV8: PENGEMBANGAN WEB BERBASIS VISUAL

Sebagai Syarat Dalam Menyelesaikan Program Studi Strata Satu (S1)
Program Studi Teknik Informatika

Disusun Oleh :

NAM A : Muhammad Taqi Wijdan
NIM : 22040700036

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH JAKARTA

2026

UNIVERSITAS MUHAMMADIYAH JAKARTA FAKULTAS TEKNIK-PRODI TEKNIK INFORMATIKA

LEMBAR PERSETUJUAN

DETEKSI JERAWAT (*ACNE VULGARIS*) MENGGUNAKAN ALGORITMA YOLOV8: PENGEMBANGAN WEB BERBASIS VISUAL

NAMA	: MUHAMMAD TAQI WIJDAN
NIM	: 22040700036
PROGRAM STUDI	: TEKNIK INFORMATIKA

TA ini telah disetujui pada tanggal,

Oleh:

Pembimbing Utama

(Mirza Sutrisno, S.SI.,M.Kom)

Mengetahui,

Ketua Program Studi Teknik Informatika

(Jumail, B.Sc., M.Sc)

UNIVERSITAS MUHAMMADIYAH JAKARTA FAKULTAS TEKNIK-PRODI TEKNIK INFORMATIKA

TANDA BUKTI PERSETUJUAN PEMBIMBING TA

Pada Semester Genap
Tahun Akademik 2026

Yang bertanda tangan dibawah ini Pembimbing TA menyetujui bahwa:

NAMA	: MUHAMMAD TAQI WIJDAN
NIM	: 22040700036
PROGRAM STUDI	: TEKNIK INFORMATIKA

DETEKSI JERAWAT (*ACNE VULGARIS*) MENGGUNAKAN ALGORITMA YOLOV8: PENGEMBANGAN WEB BERBASIS VISUAL

Dimulai bulan, tahun	: Maret, 2026
Selesai bulan, tahun	: Mei, 2026

Untuk ikut serta Ujiuan Sidang Strata Satu (S1) yang diselenggarakan oleh Program Studi Teknik Informatika Universitas Muhammadiyah Jakarta.

Jakarta, 9 Mei 2026

Pembimbing Utama



(Mirza Sutrisno, S.SI.,M.Kom)

UNIVERSITAS MUHAMMADIYAH JAKARTA FAKULTAS TEKNIK-PRODI TEKNIK INFORMATIKA

LEMBAR PENGESAHAN

DETEKSI JERAWAT (*ACNE VULGARIS*) MENGGUNAKAN ALGORITMA YOLOV8: PENGEMBANGAN WEB BERBASIS VISUAL

NAMA	: MUHAMMAD TAQI WIJDAN
NIM	22040700036
PROGRAM STUDI	: TEKNIK INFORMATIKA

TA ini telah diuji pada tanggal 29 Juli 2026

Oleh Penguji:

1. Rita Dewi Risanty, M.M.S.I :

2. Yana adharani, S.Si., M.Kom :

3. Mirza Sutrisno, S.SI.,M.Kom :

UNIVERSITAS MUHAMMADIYAH JAKARTA FAKULTAS TEKNIK-PRODI TEKNIK INFORMATIKA

LEMBAR PERNYATAAN

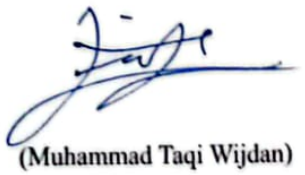
Bersama ini saya menyatakan bahwa isi yang terkandung dalam TA ini, dengan Judul:

"DETEKSI JERAWAT (*ACNE VULGARIS*) MENGGUNAKAN ALGORITMA YOLOV8: PENGEMBANGAN WEB BERBASIS VISUAL"

Adalah murni merupakan hasil penelitian dan pemikiran saya sendiri.

Demikian pernyataan ini saya buat dan siap menerima konsekuensi apapun di masa yang akan datang apabila ternyata TA ini merupakan salinan ataupun contoh karya-karya yang telah dibuat / diterbitkan sebelum tanggal TA ini.

Jakarta, 9 Mei 2026
Penulis



(Muhammad Taqi Wijdan)

SURAT PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS

Yang bertanda tangan di bawah ini, saya :

Nama	: Muhammad Taqi Wijdan
NIM	: 22040700036
Peogram Studi	: Teknik Informatika
Jenjang	: Strata Satu (S1)
Jenis Karya	: Tugas Akhir

Demi pengembangan ilmu pengetahuan, dengan ini menyetujui untuk memberikan ijin kepada pihak Program Studi Teknik Informatika FT-UMJ **Hak Bebas Royalti Non- Eksklusif** ***(Non-exclusive Royalti-Free Right)*** atas karya ilmiah saya yang berjudul :

"DETEKSI JERAWAT (*ACNE VULGARIS*) MENGGUNAKAN ALGORITMA YOLOV8: PENGEMBANGAN WEB BERBASIS VISUAL"

Dengan **Hak Bebas Royalti Non-Eksklusif** ini pihak FT-UMJ berhak menyimpan, mengalih-media atau *bentuk*-kan, mengelolanya dalam pangkalan data *(database)*, mendistribusikannya dan menampilkan atau mempublikasikannya di *internet* atau media lain untuk kepentingan akademis tanpa perlu meminta ijin dari Saya selama tetap mencantumkan nama kami sebagai penulis/pencipta karya ilmiah tersebut.

Saya bersedia untuk menanggung secara pribadi, tanpa melibatkan pihak FT- UMJ, segala bentuk tuntutan hukum yang timbul atas pelanggaran Hak Cipta dalam karya ilmiah saya ini.

Demikian pernyataan ini saya buat dengan sebenarnya.

Jakarta, 9 Mei 2026
Yang menyatakan,



(Muhammad Taqi Wijdan)

UNIVERSITAS MUHAMMADIYAH JAKARTA FAKULTAS TEKNIK-PRODI TEKNIK INFORMATIKA

DAFTAR PRESENSI BIMBINGAN TA

DETEKSI JERAWAT (*ACNE VULGARIS*) MENGGUNAKAN ALGORITMA YOLOV8: PENGEMBANGAN WEB BERBASIS VISUAL

NAMA : MUHAMMAD TAQI WIJDAN
NIM : 22040700036
PROGRAM STUDI : TEKNIK INFORMATIKA

Dosen Pembimbing Utama Mirza Sutrisno, S.SI.,M.Kom

No.	Tanggal	Catatan Dosen Pembimbing	Paraf
1.	30 Maret 2026	Diskusi mengenai judul yang ingin di ambil.	
2.	12 April 2026	ACC Judul	
3.	27 April 2026	Perbaikan pada bab 1: latar belakang dan diskusi mengenai kerangka bab 2.	
4.	4 Mei 2026	Perbaikan pada bab 2: mengenai refrensi dan penelitian terdahulu.	
5.	8 Mei 2026	Perbaikan pada bab 3, dan perbaikan keselruhan format agar sesuai dengan template TA.	
6.	9 Mei 2026	Revisi dan arahan sempro	
7.	22 Juni 2026	Mendiskusikan hasil revisi sempro	
8.	14 Juli 2026	Mendiskusikan mengenai kendala yang terjadi	

9.	18 Juli 2026	Membahas mengenai kendala yaitu model yang tidak dapat dibaca kedalam web	

Dosen Pembimbing

(Mirza Sutrisno, S.SI.,M.Kom)

INTERNALISASI AIK

Penelitian yang berjudul *"Deteksi Jerawat (Acne Vulgaris) Menggunakan Algoritma YOLOv8: Pengembangan Web Berbasis Visual"* merupakan bentuk penerapan ilmu pengetahuan dan teknologi yang sejalan dengan nilai-nilai Al-Islam dan Kemuhammadiyahan. Pemanfaatan teknologi *Artificial Intelligence* dalam penelitian ini bertujuan untuk membantu masyarakat mengenali kondisi kesehatan kulit secara lebih cepat, mudah, dan efisien sehingga dapat meningkatkan kesadaran dalam menjaga kesehatan diri.

Dalam Islam, menjaga kesehatan merupakan bagian dari ikhtiar manusia untuk merawat amanah yang diberikan oleh Allah SWT. Sebagaimana firman Allah SWT dalam Al-Qur'an:

"Dan janganlah kamu menjatuhkan dirimu sendiri ke dalam kebinasaan."
(QS. Al-Baqarah: 195)

Ayat tersebut menjelaskan bahwa manusia diperintahkan untuk menjaga diri dari hal-hal yang dapat menimbulkan bahaya, termasuk menjaga kesehatan tubuh dan kulit. Selain itu, Islam juga mendorong umatnya untuk terus menuntut ilmu dan mengembangkan teknologi yang bermanfaat bagi kehidupan manusia. Hal ini sesuai dengan firman Allah SWT:

"Bacalah dengan (menyebut) nama Tuhanmu yang menciptakan."
(QS. Al-'Alaq: 1)

Melalui penelitian ini, pengembangan teknologi YOLOv8 menjadi salah satu bentuk implementasi ilmu pengetahuan dalam bidang kesehatan berbasis digital. Penelitian ini juga sejalan dengan hadis Rasulullah SAW:

"Setiap penyakit ada obatnya."
(HR. Muslim)

Hadis tersebut mengajarkan bahwa manusia harus terus berikhtiar dalam mencari solusi terhadap suatu penyakit. Oleh karena itu, sistem deteksi jerawat berbasis web ini diharapkan dapat membantu pengguna memperoleh informasi mengenai jenis jerawat serta solusi penanganannya secara lebih praktis dan informatif.

ABSTRACT

Acne (Acne vulgaris) is a common skin problem, while the visual similarity among acne types can make independent identification difficult. This condition indicates the need for an accessible tool that provides preliminary information about the location and type of acne in facial images. This study aims to develop a system for detecting and classifying five acne types—blackheads, whiteheads, papules, pustules, and nodules—using YOLOv8 and to analyze the effect of data-split ratios and epoch counts on model performance. The study follows the AI Project Cycle, which includes problem scoping, data acquisition, data exploration, modeling, evaluation, and deployment. The annotated image dataset was obtained through Roboflow, and the YOLOv8s model was trained through transfer learning in Google Colaboratory using 640 × 640-pixel images, a batch size of 16, and a patience value of 20. The experiments compared four data-split ratios at maximum settings of 80, 100, and 120 epochs. The evaluation used precision, recall, mAP@0.5, mAP@0.5:0.95, confusion matrices, and evaluation curves. Among the 12 available experimental results, the 80:15:5 ratio with a maximum of 120 epochs produced the best temporary performance, with a precision of 0.414, recall of 0.533, mAP@0.5 of 0.485, and mAP@0.5:0.95 of 0.363. Testing on 20 new images produced detections in 17 images and no detections in 3 images, resulting in 26 bounding boxes with confidence values ranging from 0.185 to 0.702. The model was implemented in a Streamlit application that supports image, video, and camera detection. The study concludes that YOLOv8s can serve as the basis for a web-based acne detection system, although its generalization performance still requires verification using annotated test images. The system provides supporting information and is not intended for medical diagnosis.

Keywords: *Acne, YOLOv8, Object Detection, Computer Vision, Streamlit, Web-Based Application.*

ABSTRAK

Jerawat (Acne vulgaris) merupakan masalah kulit yang banyak dialami masyarakat, sedangkan kemiripan visual antarjenis jerawat dapat menyulitkan identifikasi secara mandiri. Kondisi tersebut menunjukkan perlunya alat bantu yang mudah diakses untuk memberikan informasi awal mengenai lokasi dan jenis jerawat pada citra wajah. Penelitian ini bertujuan mengembangkan sistem deteksi dan klasifikasi lima jenis jerawat, yaitu blackhead, whitehead, papula, pustula, dan nodul, menggunakan YOLOv8 serta menganalisis pengaruh variasi rasio pembagian data dan jumlah epoch terhadap performa model. Penelitian mengikuti tahapan AI Project Cycle yang meliputi perumusan masalah, pengumpulan data, eksplorasi data, pemodelan, evaluasi, dan deployment. Dataset citra beranotasi diperoleh melalui Roboflow, kemudian model YOLOv8s dilatih dengan transfer learning di Google Colaboratory menggunakan ukuran citra 640 × 640 piksel, batch size 16, dan patience 20. Eksperimen membandingkan empat rasio data pada maksimum 80, 100, dan 120 epoch. Evaluasi menggunakan precision, recall, mAP@0.5, mAP@0.5:0.95, confusion matrix, serta kurva evaluasi. Dari 12 hasil eksperimen yang tersedia, konfigurasi rasio 80:15:5 dengan maksimum 120 epoch menghasilkan performa terbaik sementara dengan precision 0,414, recall 0,533, mAP@0.5 sebesar 0,485, dan mAP@0.5:0.95 sebesar 0,363. Pengujian pada 20 citra baru menghasilkan deteksi pada 17 citra dan tidak menghasilkan deteksi pada 3 citra, dengan total 26 bounding box dan confidence 0,185–0,702. Model kemudian diterapkan pada aplikasi Streamlit yang menyediakan deteksi gambar, video, dan kamera. Penelitian menyimpulkan bahwa YOLOv8s dapat digunakan sebagai dasar sistem deteksi jerawat berbasis web, tetapi ketepatan generalisasi masih perlu diverifikasi menggunakan citra uji beranotasi. Sistem berfungsi sebagai alat bantu informasi dan bukan sebagai alat diagnosis medis.

Kata Kunci: Jerawat, YOLOv8, Deteksi Objek, Computer Vision, Streamlit, Aplikasi Berbasis Web.

KATA PENGANTAR

Segala puji dan syukur hanya milik Allah SWT. Dengan mengucapkan *Alhamdulillahirabbil'alamin*, penulis memanjatkan puji dan syukur atas limpahan rahmat, taufik, kesehatan, serta hidayah-Nya, sehingga Tugas akhir ini dapat diselesaikan dengan baik. Penulis menyadari bahwa penyusunan laporan ini tidak akan berhasil tanpa bantuan, arahan, serta bimbingan dari berbagai pihak.

Oleh karena itu, dengan penuh rasa hormat dan terima kasih, penulis ingin menyampaikan apresiasi kepada:

1. Bapak Prof. Dr. Ma'mun Murod, S.Sos., M.Si., selaku Rektor Universitas Muhammadiyah Jakarta.
2. Bapak Dr. Ir. Irfan Purnawan, S.T., M.Chem.Eng., selaku Dekan Fakultas Teknik Universitas Muhammadiyah Jakarta.
3. Bapak Jumail, M.Sc., selaku Ketua Program Studi Teknik Informatika Universitas Muhammadiyah Jakarta.
4. Bapak Mirza Sutrisno, S.SI.,M.Kom., selaku Dosen Pembimbing yang telah membimbing penulis hingga tugas akhir ini selesai.
5. Kedua orang tua,kaka-kaka dan abang-abang penulis yang selalu saya cintai dan hormati karena pengorbanan jiwa dan raga mereka lah saya bisa berada di titik ini dan tak lupa Mamah yang *insyaallah* berada di surga meskipun tidak ada secara langsung di samping penulis tetapi raganya selalu berada disisi penulis yang memotivasi penulis hingga dititik ini.
6. Kepada Zhi, seseorang yang saya cintai, yang senantiasa menemani, memberikan semangat, dukungan, serta motivasi kepada penulis selama proses penyusunan dan penyelesaian tugas akhir ini. Terima kasih telah menjadi tempat berbagi cerita, memberikan dorongan di saat penulis merasa lelah, serta selalu hadir dalam setiap proses yang dilalui hingga tugas akhir ini dapat diselesaikan.
7. Kepada teman-teman angkatan 2022, yang selalu mendukung dan membantu penulis dalam segala kesulitan yang dihadapi.

Penulis menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, penulis sangat mengharapkan saran dan kritik yang membangun untuk perbaikan di masa mendatang.Akhir kata, semoga laporan ini dapat memberikan manfaat bagi semua pihak, baik saat ini maupun di masa yang akan datang.

Jakarta, 28 Agustus 2026



Muhammad Taqi Wijdan

DAFTAR ISI

LEMBAR PERSETUJUAN.....**Error! Bookmark not defined.**

TANDA BUKTI PERSETUJUAN PEMBIMBING TA ..... **Error! Bookmark not defined.**

LEMBAR PENGESAHAN .....**Error! Bookmark not defined.**

LEMBAR PERNYATAAN .....**Error! Bookmark not defined.**

DAFTAR PRESENSI BIMBINGAN TA.....**Error! Bookmark not defined.**

INTERNALISASI AIK x

ABSTRACT xi

ABSTRAK xii

KATA PENGANTAR.....**Error! Bookmark not defined.**

DAFTAR ISI xiv

DAFTAR TABEL..... xvii

DAFTAR GAMBAR xviii

BAB I PENDAHULUAN 1

1.1 Latar Belakang Masalah..... 1

1.2 Identifikasi Masalah 3

1.3 Rumusan Masalah 3

1.4 Batasan Masalah..... 3

1.5 Tujuan Penelitian..... 4

1.6 Metodologi Penelitian 5

1.7 Sistematika Penulisan 5

BAB II TINJAUAN PUSTAKA 7

2.1 Jerawat (Acne Vulgaris)..... 7

2.2 Machine Learning 16

2.3 YOLOv8 17
2.3.1 Cara Kerja YOLOv8 18
2.4 Confusion Matrix 26
2.5 AI *Project Cycle* 29
2.5.1 Problem Scoping 30
2.5.2 Data Acquisition 30
2.5.3 Data Exploration 30
2.5.4 Modeling 33
2.5.5 Evaluation 33
2.5.6 Deployment 34
2.6 Evaluasi 34
2.7 Penelitian Terdahulu 35
2.8 GAP Analisis 37
BAB III METODE PENELITIAN 38
3.1 Tahap Penelitian 38
3.2 Problem Scoping 38
3.3 Data Acquisition 39
3.4 Data Exploration 41
3.4.1 Labeling 41
3.4.2 Resizing Image: 42
3.4.3 Augmentation 43
3.4.4 Rancangan Eksperimen 43
3.5 Modeling 45
3.5.1 Perhitungan pada Proses Modeling YOLOv8 45
3.6 Evaluation 58

3.6.1 Precision 58
3.6.2 Recall 59
3.6.3 Mean Average Precision (mAP) 59
3.6.4 Confusion Matrix dan F1-Confidence 60
3.7 Deployment 61
BAB IV HASIL DAN PEMBAHASAN 64
4.1 Hasil Penelitian 64
4.1.1 Hasil Akuisisi dan Persiapan dataset 64
4.1.2 Hasil Konfigurasi Pelatihan Model 65
4.1.3 Hasil Eksperimen Variasi Konfigurasi 67
4.1.4 Hasil Evaluasi Model 68
4.1.5 Hasil Pengujian pada Citra Baru 73
4.1.6 Hasil Penyimpanan Model 74
4.2 Pembahasan 75
4.2.1 Analisis Konfigurasi Pelatihan 75
4.2.2 Analisis Kinerja Model 75
4.2.3 Analisis Kesalahan dan Generalisasi 75
4.3 Deployment 77
BAB V PENUTUP 84
5.1 Kesimpulan 84
5.2 Saran 85
DAFTAR PUSTAKA 86

DAFTAR TABEL

Tabel 2. 1 Keterangan Sistem Koordinat dan Parameter Bounding Box 21
Tabel 2. 2 Penelitian Terdahulu dan Research GAP 35
Tabel 3. 1 Problem Scoping 39
Tabel 3. 2 Dataset Jerawat..... 40
Tabel 3. 3 Rancangan Eksperimen Model YOLOv8..... 44
Tabel 4. 1 Distribusi Dataset Berdasarkan Kelas 64
Tabel 4. 2 Konfigurasi Pelatihan Model YOLOv8..... 65
Tabel 4. 3 Perbandingan Hasil Eksperimen 67
Tabel 4. 4 Hasil Evaluasi Model Terbaik 68
Tabel 4. 5 Hasil Evaluasi per Kelas pada Konfigurasi 120 Epoch..... 69
Tabel 4. 6 ingkasan Hasil Pengujian pada 20 Citra Baru 76

DAFTAR GAMBAR

Gambar 2. 1 Komedo Terbuka (Blackheads) 8
Gambar 2. 2 Komedo Tertutup (Whiteheads) 10
Gambar 2. 3 Jerawat Papula 12
Gambar 2. 4 Jerawat Pustula 13
Gambar 2. 5 Nodul 14
Gambar 2. 7 Machine Learning 16
Gambar 2. 9 Alur Cara Kerja YOLOv8 18
Gambar 2. 10 Confusion Matrix 27
Gambar 2. 11 AI Project Cycle 29
Gambar 3. 1 Diagram Alur AI Project Cycle 38
Gambar 3. 2 Folder Citra yang sudah lolos verifikasi 40
Gambar 3. 3 Citra Jerawat Sebelum pelabelan 41
Gambar 3. 4 Citra sesudah Pelabelan 42
Gambar 3. 5 Proses Resizing Citra pada Roboflow 42
Gambar 3. 6 Konfigurasi Augmentasi pada Roboflow 43
Gambar 3. 7 Flowchart Implementasi YOLOv8 45
Gambar 3. 8 Tampilan Dashboard 61
Gambar 3. 9 Tampilan Unggah foto 62
Gambar 3. 10 Tampilan Unggah Video 62
Gambar 3. 11 Fitur kamera visual secara real-time 63
Gambar 4. 1 Grafik Hasil Pelatihan Model YOLOv8 66
Gambar 4. 2 Confusion Matrix Model YOLOv8 70
Gambar 4. 3 Confusion Matrix Ternormalisasi 70
Gambar 4. 4 Kurva Precision-Confidence 71
Gambar 4. 5 Kurva Recall-Confidence 72
Gambar 4. 6 Kurva F1-Confidence 72
Gambar 4. 7 Kurva Precision-Recal 73
Gambar 4. 8 Hasil Pengujian Model pada Citra Baru 74
Gambar 4. 9 Tampilan Dashboard 78
Gambar 4. 10 Tampilan Unggah foto 79
Gambar 4. 11 Tampilan Unggah Video 80
Gambar 4. 12 Fitur kamera visual secara real-time 82

BAB I

PENDAHULUAN

1.1Latar Belakang Masalah

Perkembangan teknologi kecerdasan buatan (*Artificial Intelligence*) dalam satu dekade terakhir telah membawa transformasi fundamental dalam berbagai sektor, terutama di bidang kesehatan.Integrasi *Machine Learning* dan *Deep Learning* memungkinkan pengembangan sistem cerdas yang mampu mendeteksi pola medis dengan tingkat akurasi yang tinggi (Fadhillah, 2026). Salah satu cabang utama yang berkembang pesat adalah *Computer Vision*, yang memungkinkan mesin untuk menginterpretasikan data visual guna mendukung diagnosis medis secara otomatis. Dalam bidang dermatologi, penggunaan sistem berbasis AI telah menunjukkan potensi besar dalam membantu tenaga profesional melakukan diagnosis dini terhadap berbagai kondisi patologis kulit, yang pada akhirnya meningkatkan efisiensi layanan kesehatan dan keselamatan pasien (Agustin et al., 2024).

Kesehatan kulit merupakan salah satu indikator penting dalam kualitas hidup manusia, di mana jerawat (*Acne Vulgaris*) menjadi penyakit inflamasi kulit kronis yang paling umum dijumpai secara global. Secara klinis, jerawat dipicu oleh interaksi kompleks faktor internal seperti sekresi sebum berlebih dan aktivitas hormonal, serta faktor eksternal seperti kolonisasi bakteri *Propionibacterium acnes* (Kalingga et al., 2024). Fenomena ini dialami oleh sekitar 80-85% remaja di seluruh dunia. Di Indonesia, prevalensi tertinggi ditemukan pada kelompok usia produktif 16–25 tahun dengan angka kejadian mencapai 53,2%. Dampak jerawat tidak terbatas pada gangguan fisik semata, namun juga memicu tekanan psikologis berat, menurunkan rasa percaya diri, hingga meningkatkan risiko kecemasan dan depresi pada penderitanya (Putranda et al., 2021).

Meskipun prevalensi jerawat sangat tinggi, masyarakat seringkali menghadapi kesulitan signifikan dalam mengidentifikasi jenis jerawat secara mandiri. Hal ini disebabkan oleh sifat jerawat yang *pleomorfik*, di mana lesi dapat bervariasi secara visual mulai dari tipe non-inflamasi (komedo terbuka dan tertutup) hingga tipe

inflamasi (papula, pustula, nodul, dan kista) (Arifianto, 2020). Setiap jenis lesi memiliki karakteristik morfologi dan protokol penanganan medis yang berbeda; kesalahan identifikasi berisiko pada pemilihan terapi yang tidak tepat yang justru memperparah kondisi kulit. Selain itu, kendala konsultasi dengan dokter kulit profesional seperti biaya yang relatif tinggi, keterbatasan waktu, serta akses layanan spesialis yang tidak merata di berbagai wilayah Indonesia menjadi penghambat utama bagi masyarakat untuk mendapatkan diagnosa yang akurat (Marshalia, 2024).

Solusi teknologi berbasis *Computer Vision* menawarkan mekanisme deteksi objek otomatis pada citra wajah untuk menjembatani kesenjangan akses tersebut. Di antara berbagai algoritma pendeteksi objek, seri YOLOv8 (*You Only Look Once* versi 8) yang dikembangkan oleh Ultralytics diakui sebagai salah satu arsitektur paling mutakhir dalam menyeimbangkan kecepatan pemrosesan *real-time* dengan akurasi spasial yang tinggi (Giezka et al., 2024). YOLOv8 memperkenalkan modifikasi arsitektural berupa *Custom CSPDarknet53* dan pendekatan *anchor-free* yang memprediksi titik pusat objek secara langsung. Fitur ini sangat menguntungkan untuk mendeteksi objek biologis seperti jerawat yang memiliki variasi morfologi dan ukuran yang sangat dinamis pada area wajah (Mudin et al., 2026)

Urgensi penelitian ini terletak pada kebutuhan akan sistem identifikasi dini yang objektif bagi penderita jerawat di Indonesia. Dengan membangun model yang dioptimalkan pada karakteristik kulit lokal, penelitian ini berkontribusi pada pengembangan ilmu pengetahuan di bidang Informatika, khususnya mengenai optimasi deteksi objek medis skala kecil. Manfaat praktisnya adalah tersedianya alat bantu mandiri bagi masyarakat untuk mengetahui kondisi kulit mereka secara cepat dan murah, sekaligus memberikan edukasi mengenai langkah penanganan yang tepat berdasarkan jenis jerawat yang terdeteksi.

Berdasarkan analisis tersebut, penelitian ini bertujuan untuk mengevaluasi performa algoritma YOLOv8 melalui eksperimen sistematis pada rasio data dan siklus pelatihan guna membangun sistem deteksi yang handal. Implementasi sistem ke dalam platform web interaktif diharapkan dapat mempermudah aksesibilitas

pengguna dalam melakukan skrining mandiri. Oleh karena itu, penelitian ini berjudul: **"Penerapan YOLOv8 untuk Deteksi dan Klasifikasi Jenis Jerawat (*Acne Vulgaris*) pada Wajah Orang Indonesia Berbasis Web"**.

1.2 Identifikasi Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka permasalahan yang dapat diidentifikasi adalah sebagai berikut:

1. Belum optimalnya pemanfaatan sistem deteksi jerawat berbasis web yang mampu mengidentifikasi jenis jerawat secara otomatis, cepat, dan mudah diakses mengakibatkan proses skrining awal jerawat masih bergantung pada pemeriksaan langsung oleh tenaga medis.
2. Belum optimalnya penerapan teknologi *Artificial Intelligence*, khususnya *Computer Vision*, dalam deteksi jerawat mengakibatkan belum terciptanya sistem yang mampu mengidentifikasi jenis jerawat dengan tingkat akurasi yang tinggi serta mudah digunakan oleh masyarakat.

1.3Rumusan Masalah

Berdasarkan latar belakang dan identifikasi masalah diatas maka rumusan masalah dalam penelitian ini diantaranya sebagai berikut:

1. Bagaimana performa algoritma YOLOv8 dalam mendeteksi jenis jerawat (*Acne Vulgaris*) pada citra wajah masyarakat Indonesia?
2. Bagaimana pengaruh variasi rasio pembagian dataset dan jumlah epoch terhadap performa algoritma YOLOv8 dalam mendeteksi dan mengklasifikasikan jenis jerawat?

1.4Batasan Masalah

Adapun batasan batasan masalah yang digunakan dalam penelitian ini adalah:

1. Penelitian ini menggunakan algoritma YOLOv8 sebagai model utama untuk mendeteksi dan mengklasifikasikan jenis jerawat pada wajah.

2. Objek penelitian dibatasi pada wajah masyarakat Indonesia, dengan area deteksi hanya pada bagian wajah (dahi, pipi, hidung, dan dagu).
3. Jenis jerawat yang dideteksi pada penelitian ini terdiri dari *Blackheads* (Komedo Terbuka), *Whiteheads* (Komedo Tertutup), Papula, Pustula, dan Nodul.
4. Dataset yang digunakan merupakan citra wajah masyarakat Indonesia yang telah melalui proses anotasi, dengan jumlah data minimal 50 citra untuk setiap kelas jerawat.
5. Platform yang digunakan dalam penelitian meliputi Roboflow untuk proses anotasi dan pengelolaan dataset, serta Google Colaboratory sebagai lingkungan pelatihan model menggunakan bahasa pemrograman Python.
6. Penelitian ini berfokus pada eksperimen optimasi model YOLOv8 melalui variasi rasio pembagian dataset (training, validation, dan testing) serta jumlah epoch untuk memperoleh performa deteksi terbaik.
7. Sistem yang dikembangkan hanya berfungsi untuk mendeteksi dan mengklasifikasikan jenis jerawat pada citra wajah, serta tidak digunakan sebagai alat diagnosis medis maupun penentu tingkat keparahan jerawat.

1.5Tujuan Penelitian

Tujuan dan manfaat yang dapat diperoleh penelitian ini adalah sebagai berikut:

1. Menganalisis performa algoritma YOLOv8 dalam mendeteksi dan mengklasifikasikan jenis jerawat pada citra wajah masyarakat Indonesia berdasarkan precision, recall, F1-score, mAP@0.5, mAP@0.5:0.95, dan confusion matrix.
2. Menganalisis pengaruh variasi rasio pembagian dataset dan jumlah epoch terhadap performa algoritma YOLOv8 serta menentukan konfigurasi yang menghasilkan performa terbaik dalam mendeteksi dan mengklasifikasikan jenis jerawat.

3. Menentukan konfigurasi rasio pembagian data dan jumlah epoch yang paling optimal untuk menghasilkan performa terbaik pada model YOLOv8 dalam mendeteksi dan mengklasifikasikan jenis jerawat.
4. Mengevaluasi kemampuan sistem dalam mendeteksi lokasi jerawat serta mengklasifikasikan jenis jerawat pada citra wajah berdasarkan hasil pengujian model YOLOv8.

1.6 Metodologi Penelitian

Penelitian ini melibatkan beberapa tahapan sebagai berikut:

1. *Problem Scoping:* Proses identifikasi atau memetakan batasan masalah yang ingin diselesaikan sehingga tujuan atau target menjadi semakin jelas dan lebih terarah serta akan lebih mudah untuk menemukan solusi
2. *Data Acquisition:* Pada proses ini mengumpulkan data-data yang dibutuhkan menggunakan *Kaggle.* Data ini yang akan menjadi dasar atau bahan selanjutnya untuk diolah.
3. *Data Exploration:* Pada proses ini menjelajahi dataset untuk memahami isi,komponen,dan karakteristiknya melalui *Exploratory Data Analysis (*EDA) sehingga dapat mengetahui pola data tersebut.
4. *Modelling:* Menggunakan YOLOv8 untuk membangun suatu model utama. Model deteksi yang digunakan untuk mengidentifikasi jenis-jenis jerawat.
5. *Evaluation:* Pada proses ini pemilihan model terbaik yang akan digunakan untuk membuat alat pendeteksi jerawat dengan memperhatikan beberapa komponen antara lain akurasi,presisi,recall.
6. *Deployment:* Model yang telah di evaluasi akan diimplementasikan menggunakan sebuah web. Hasil implementasi ini diharapkan dapat memberikan solusi untuk menemukan cara agar mengurangi jerawat.

1.7 Sistematika Penulisan

Sistematika penulisan pada penelitian ini disusun kedalam lima bab, antara lain:

BAB I PENDAHULUAN

Pada bab ini berisi mengenai Latar Belakang, Identifikasi Masalah, Rumusan Masalah, Batasan Masalah, Tujuan Penelitian, Metodologi penelitian, dan Sistematika Penelitian.

BAB II LANDASAN TEORI

Berisi mengenai landasan teori yang berkaitan dengan Jerawat, *Deep Learning*, YOLOv8, dan Kerangka berfikir.

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan metode yang digunakan dalam penelitian, mencakup beberapa tahapan utama, yaitu *Problem Scoping, Data Acquisition, Data Exploration, Modelling, Evaluation, dan Deployment*.

BAB IV HASIL DAN PEMBAHASAN

Pada bab ini berisi mengenai Proses implementasi YOLOv8, training, hasil pengujian, dan analisis performa.

BAB V PENUTUP

BAB II
TINJAUAN PUSTAKA

2.1 Jerawat (Acne Vulgaris)

Jerawat atau *Acne Vulgaris* merupakan gangguan pada kulit yang bersifat kronis dan biasanya muncul akibat peradangan pada folikel rambut serta kelenjar minyak (folikel pilosebasea). Kondisi ini terjadi ketika pori-pori tersumbat oleh minyak berlebih (*sebum*), sel-sel kulit mati, dan terkadang terinfeksi oleh bakteri *Cutibacterium acnes* (sebelumnya dikenal sebagai *Propionibacterium acnes*) (Asbullah, 2021). Masalah kulit ini umum dialami oleh remaja hingga orang dewasa muda karena pada masa tersebut aktivitas hormon meningkat cukup signifikan. Beberapa faktor lain yang dapat memperparah timbulnya jerawat antara lain faktor keturunan, stres, produksi minyak berlebih oleh kelenjar sebasea, kebersihan kulit yang kurang terjaga, pola makan yang tidak seimbang, serta penggunaan produk kosmetik yang dapat menyumbat pori-pori. (Retno Try Lestari, 2021)

Jerawat umumnya muncul pada masa remaja, khususnya saat seseorang mulai memasuki masa pubertas. Pada fase ini, aktivitas hormon meningkat sehingga memicu produksi minyak berlebih pada kulit. Berdasarkan data epidemiologis, sekitar 80–85% remaja pernah mengalami jerawat dengan tingkat kejadian tertinggi pada usia 15 hingga 18 tahun. Kasus jerawat juga masih ditemukan pada 12% perempuan berusia di atas 25 tahun dan sekitar 3% pada kelompok usia 35–44 tahun. Kasus jerawat yang tergolong berat lebih sering dijumpai pada laki-laki yang memiliki kebiasaan merokok. Menurut catatan Kelompok Studi Dermatologi Kosmetika Indonesia (KSDKI), jumlah penderita jerawat di Indonesia mencapai 60% pada tahun 2006 dan meningkat menjadi 80% pada tahun 2007. Secara umum, insiden jerawat pada usia dewasa muda mencapai 80–100%, terutama pada rentang usia 14–17 tahun pada perempuan dan 16–19 tahun pada laki-laki. (Nava Muzdalifah, 2020).

Secara umum, jerawat (*acne vulgaris*) dapat diklasifikasikan ke dalam beberapa jenis berdasarkan bentuk dan tingkat keparahannya. Setiap jenis jerawat memiliki ciri khas tersendiri yang membedakannya dari segi penampilan maupun proses peradangannya. Berikut ini merupakan uraian mengenai beberapa tipe jerawat yang sering ditemukan:

2.1.1 Komedo Terbuka (*Blackheads)*



Gambar 2. 1 Komedo Terbuka (Blackheads)

Jenis jerawat ini timbul ketika pori-pori kulit tersumbat oleh kombinasi sebum (minyak berlebih), sel kulit mati, dan bakteri. Bagian atas pori yang terbuka kemudian terpapar udara, sehingga terjadi proses oksidasi yang mengubah warnanya menjadi gelap kehitaman. Secara umum, jerawat jenis ini memiliki ciri khas berupa bintik hitam kecil pada permukaan kulit, tidak menimbulkan peradangan maupun pembengkakan, dan paling sering muncul di bagian hidung, dagu, serta dahi. Gambar II-1 adalah contoh dari jerawat dengan Jenis komedo terbuka (*Blackheads).*

Penyebab jerawat ini biasanya muncul karena perubahan hormon atau bisa juga karena pori-pori yang terbuka kemudian terisi dengan kotoran pada akhirnya pori-pori lainnya tersumbat dan terkena paparan udara yang menyebabkan warnanya menjadi warna hitam. (Fadli, 2024)

Banyak solusi untuk menghilangkan dari jerawat dengan jenis komedo terbuka (*Blackheads)*, yaitu dengan cara :

2.1.1.1 Cuci muka minimal dua kali sehari

Rutin mencuci muka membantu mencegah kotoran dan minyak yang menumpuk di pori-pori, Ini menjadi salah satu dari tiga langkah terpenting dalam rutinitas perawatan kulit untuk alasan yang baik dengan membersihkan kulit secara teratur dapat membantu untuk menghilangkan kotoran, minyak, sel kulit mati, bakteri, atau riasan yang tertinggal di wajah.

2.1.1.2 Menggunakan *Chemical Exfoliator*

Cara yang lembut dan efektif untuk memecah kulit mati dan minyak yang menyumbat dalam pori-pori, kemudian bahan-bahan yang digunakan dalam pengelupasan kimia melarutkan sel-sel kulit mati sehingga mudah dibersihkan. Adapun bahan- bahan yang digunakan biasanya asam *alfa-hidroksi (AHA)* seperti asam *glikolat* dan asam *laktat* serta asam *beta-hidroksi (BHA),* seperti asam *silsilat.*

Menurut jurnal ilmiah berjudul *A double-blind, placebo-controlled evaluation of a 2% salicylic acid cleanser for improvement of acne vulgaris,* yang dipublikasikan di *Journal of The American Academy of Dermatology*, asam salisilat dapat mengurangi jumlah lesi jerawat termasuk juga menurunkan pertumbuhan komedo.

2.1.1.3 Cuci muka setelah berolahraga

Biasanya ketika berolahraga menyebabkan keringat yang berlebih, kemudian keringat yang berlebih dapat menyatu dengan kotoran,bakteri,dan sel kulit mati untuk menyumbat pori-pori yang dapat memungkinkan menyebabkan komedo hitam, maka dari itu sangat penting untuk mencuci muka sebelum ataupun sesudah berolahraga atau dalam keadaan apapun yang menyebabkan keringat berlebih. (Dimas, 2025)

2.1.2 Komedo Tertutup (*Whiteheads)*



Gambar 2. 2 Komedo Tertutup (Whiteheads)

Komedo tertutup (*whiteheads*) terjadi ketika minyak (sebum) dan sel kulit mati bercampur sehingga menyumbat pori-pori. Jenis komedo ini merupakan tahap awal sebelum berkembang menjadi bentuk jerawat lainnya, dan biasanya tampak sebagai benjolan kecil berwarna putih pada permukaan kulit.

Penyebab jerawat ini sama dengan penyebab jerawat *blackheads* yaitu adanya perubahan hormon, pada masa-masa tertentu, yakni pada masa pubertas dan haid jumlah sebum atau minyak diproduksi pori-pori akan meningkat sehingga pori-pori pun akan tersumbat dan menyebabkan komdo putih, biasanya komedo yang tertutup ini akan muncul di daerah yang mengalami banyak gesekan seperti dagu atau garis rahang. (azmi, 2025)

Adapun solusi untuk menghilangkan dari jerawat dengan jenis komedo terbuka (*Blackheads)*, yaitu dengan cara :

2.1.2.1 AHA (*Alfa hydroxy acid)*

AHA (*alpha hydroxy acid*) atau asam alfa hidroksi merupakan senyawa asam yang telah lama digunakan dalam perawatan kulit, khususnya untuk membantu mengatasi jerawat. Senyawa ini bekerja dengan cara mengeksfoliasi kulit, yaitu mengangkat sel-sel kulit mati dengan melepaskannya dari permukaan kulit, dengan begitu sel kulit mati akan terbuang dan pori-pori tidak menyempit agar tidak adanya penyumbatan.

Sebuah studi yang dipublikasikan dalam International Journal of Cosmetic Science menyatakan bahwa penggunaan larutan AHA dengan konsentrasi 4% efektif dalam membantu mengatasi komedo tertutup (*whiteheads*) maupun komedo terbuka (*blackheads).*

2.1.2.2 Krim yang mengandung *retinoid*

Selain AHA, senyawa lain yang umum digunakan dalam pengobatan komedo adalah retinoid. Retinoid merupakan turunan vitamin A yang berperan dalam mengurangi peradangan serta membantu mempercepat regenerasi sel kulit.

Senyawa ini dinilai efektif dalam mempercepat penyembuhan peradangan kulit akibat penyumbatan pori-pori. Pada beberapa kasus, retinoid juga digunakan dalam kombinasi dengan obat lain terutama untuk mengatasi jerawat nodul.

Penggunaan retinoid topikal tidak hanya diaplikasikan pada area yang berkomedo, tetapi juga secara merata pada seluruh wajah untuk mendapatkan hasil yang optimal. Namun, penggunaan retinoid dapat meningkatkan sensitivitas kulit terhadap sinar matahari, sehingga disarankan untuk digunakan pada malam hari sebelum tidur.

2.1.2.3 *Benzoil peroksida*

Benzoil peroksida (*benzoyl peroxide*) merupakan senyawa yang memiliki sifat antibakteri kuat, sehingga efektif dalam mengurangi peradangan akibat infeksi bakteri pada kulit. Selain itu, senyawa ini juga berperan dalam menurunkan produksi minyak (sebum) berlebih pada kulit.

Benzoil peroksida tersedia dalam berbagai bentuk sediaan, seperti sabun pembersih wajah, toner, maupun krim topikal. Namun, penggunaannya dapat menyebabkan efek samping berupa kulit kering, sehingga perlu digunakan secara bijak dan sesuai anjuran. Pada tahap awal penggunaan, disarankan untuk memilih produk dengan konsentrasi rendah, yaitu sekitar 2%, guna meminimalkan risiko iritasi pada kulit. (Puji, 2024)

2.1.3 Papula



Gambar 2. 3 Jerawat Papula

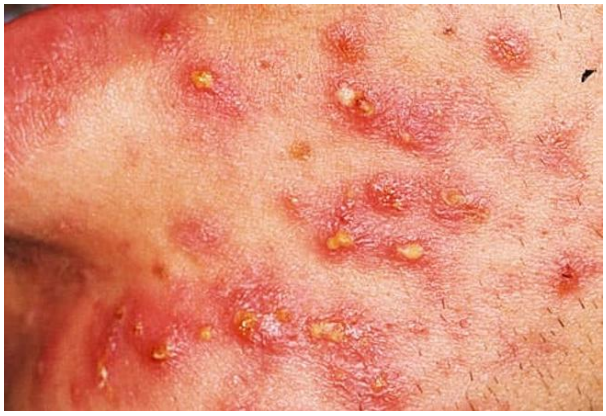
Jerawat papula merupakan salah satu jenis jerawat yang bersifat inflamasi, yang ditandai dengan munculnya benjolan kecil berwarna kemerahan di permukaan kulit tanpa adanya nanah. Kondisi ini terjadi karena adanya peradangan pada *folikel pilosebasea* yang tersumbat oleh sebum (minyak) dan sel kulit mati. Selain itu, pertumbuhan bakteri seperti *Propionibacterium acnes* juga turut memicu terjadinya peradangan tersebut. Dalam dunia medis, papula termasuk ke dalam kelompok jerawat inflamasi bersama pustula, nodul, dan kista, yang umumnya muncul pada area wajah, dada, maupun punggung.(Harlim et al., 2025)

Terbentuknya jerawat papula dipengaruhi oleh beberapa faktor utama, seperti produksi sebum yang berlebihan, proses *hiperkeratinisasi* atau penumpukan sel kulit mati pada *folikel*, serta pertumbuhan bakteri yang dapat memicu peradangan pada kulit. Selain faktor *internal* tersebut, kondisi jerawat juga dapat dipengaruhi oleh faktor *eksternal*, seperti penggunaan kosmetik yang kurang sesuai, pola hidup yang tidak teratur, tingkat stres, serta paparan lingkungan. Berbagai faktor ini dapat saling berinteraksi dan memperburuk kondisi jerawat yang muncul.(Sifatullah & Zulkarnain, 2021)

Penanganan jerawat papula umumnya dilakukan melalui perawatan kulit yang bertujuan untuk mengontrol produksi minyak, menghambat pertumbuhan bakteri, serta mengurangi peradangan pada kulit. Beberapa langkah yang dapat dilakukan antara lain penggunaan obat topikal seperti asam *salisilat, benzoyl peroxide*, dan *retinoid*, serta menjaga kebersihan wajah secara rutin. Selain itu, kebiasaan

memencet jerawat sebaiknya dihindari karena dapat memperparah kondisi kulit. Penggunaan produk perawatan yang bersifat *non-komedogenik* juga dianjurkan agar tidak menyumbat pori-pori. Secara umum, penanganan ini berfokus pada upaya mengurangi produksi sebum, menekan aktivitas bakteri, dan meredakan peradangan sebagai penyebab utama jerawat.(Sifatullah & Zulkarnain, 2021)

2.1.4 Pustula



Gambar 2. 4 Jerawat Pustula

Jerawat pustula merupakan salah satu jenis jerawat inflamasi yang ditandai dengan munculnya benjolan berisi nanah di permukaan kulit. Biasanya, bagian tengah jerawat ini tampak berwarna putih atau kekuningan dan dikelilingi oleh area kemerahan akibat peradangan. Pustula terbentuk sebagai lanjutan dari pori-pori yang tersumbat oleh sebum (minyak) dan sel kulit mati, yang kemudian mengalami infeksi bakteri. Dalam klasifikasi jerawat, pustula termasuk ke dalam kelompok jerawat inflamasi bersama papula, nodul, dan kista, yang umumnya muncul pada area wajah, dada, maupun punggung.(Andini Rizqi et al., 2025)

Terbentuknya jerawat pustula dipengaruhi oleh beberapa faktor utama, seperti produksi sebum yang berlebihan, proses *hiperkeratinisasi* yang menyebabkan penumpukan sel kulit mati pada pori-pori, serta pertumbuhan bakteri yang memicu terjadinya peradangan pada kulit. Selain faktor internal tersebut, kondisi jerawat juga dapat diperburuk oleh faktor eksternal, seperti penggunaan kosmetik yang tidak sesuai, kebersihan kulit yang kurang terjaga, pola makan, serta kualitas tidur (Asbullah et al., 2021). Kombinasi antara faktor-faktor tersebut dapat

memperparah peradangan hingga akhirnya menyebabkan terbentuknya nanah pada jerawat pustula.

Penanganan jerawat pustula umumnya dilakukan dengan tujuan untuk mengurangi peradangan, menghambat pertumbuhan bakteri, serta mengontrol produksi minyak pada kulit. Beberapa upaya yang dapat dilakukan antara lain penggunaan obat topikal seperti *benzoyl peroxide*, asam *salisilat*, dan *retinoid* yang dikenal efektif dalam mengatasi jerawat yang bersifat inflamasi. Selain itu, menjaga kebersihan wajah secara rutin juga penting untuk mencegah penumpukan kotoran dan minyak pada pori-pori. Kebiasaan memencet jerawat sebaiknya dihindari karena dapat memperparah peradangan dan berisiko menimbulkan bekas luka. Penggunaan produk perawatan kulit yang bersifat *non-komedogenik* juga dianjurkan agar tidak menyumbat pori-pori. Secara umum, penanganan ini berfokus pada pengendalian produksi sebum, pertumbuhan bakteri, serta peradangan sebagai faktor utama penyebab jerawat.(Maulida & Topik, 2024)

2.1.5 Nodul



Gambar 2. 5 Nodul

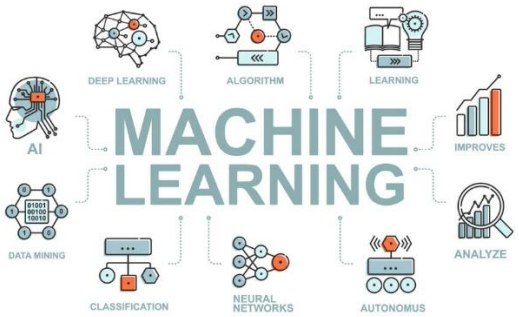
Jerawat nodul merupakan salah satu jenis jerawat inflamasi yang termasuk dalam kategori cukup parah, yang ditandai dengan munculnya benjolan berukuran besar, terasa keras, dan menimbulkan nyeri karena terbentuk di lapisan kulit yang lebih dalam. Berbeda dengan jerawat pustula, nodul umumnya tidak memiliki bagian puncak yang berisi nanah, melainkan berkembang sebagai peradangan yang terjadi di jaringan kulit bagian dalam. Dalam klasifikasi jerawat, nodul termasuk ke dalam

kelompok jerawat inflamasi bersama papula, pustula, dan kista, yang biasanya muncul pada area wajah, dada, maupun punggung.(Achmad et al., 2021)

Terbentuknya jerawat nodul dipengaruhi oleh beberapa faktor utama, seperti produksi sebum yang berlebihan, penumpukan sel kulit mati *(hiperkeratinisasi*), serta pertumbuhan bakteri yang memicu peradangan pada kulit. Kondisi ini menyebabkan pori-pori tersumbat dan berkembang menjadi peradangan yang lebih dalam dan serius. Selain itu, faktor lain seperti perubahan hormon, stres, pola makan, serta penggunaan kosmetik yang tidak sesuai juga dapat memperburuk kondisi jerawat. Kombinasi dari berbagai faktor tersebut dapat meningkatkan tingkat peradangan hingga akhirnya membentuk benjolan keras yang menjadi ciri khas jerawat nodul.(Akbar & Pramuningtyas, 2024)

Penanganan jerawat nodul umumnya memerlukan perhatian yang lebih intensif dibandingkan dengan jenis jerawat yang lebih ringan. Perawatan dasar seperti penggunaan obat topikal, misalnya *benzoyl peroxide, asam salisilat, dan retinoid*, dapat membantu mengontrol produksi minyak serta menghambat pertumbuhan bakteri pada kulit. Namun, pada kondisi yang lebih parah, penanganan medis seperti pemberian *antibiotik* atau terapi khusus dari dokter kulit sering kali diperlukan untuk mengatasi peradangan yang lebih dalam. Selain itu, menjaga kebersihan wajah secara rutin, menghindari kebiasaan memencet jerawat, serta menggunakan produk perawatan yang bersifat non-komedogenik juga penting untuk mencegah kondisi semakin memburuk. Secara umum, penanganan jerawat nodul difokuskan pada upaya mengurangi produksi sebum, menekan aktivitas bakteri, serta meredakan peradangan pada kulit.(Listiawan et al., 2022)

2.2 Machine Learning



Gambar 2. 6 *Machine Learning*

Machine Learning merupakan salah satu cabang dari ilmu komputer yang berfokus pada perancangan algoritma agar komputer dapat belajar dari data. Pendekatan ini memungkinkan sistem untuk mengenali pola dan membuat keputusan tanpa harus diprogram secara eksplisit untuk setiap kondisi. Oleh karena itu, *machine learning* sering disebut sebagai proses *learning from data*, yaitu memanfaatkan data masa lalu untuk melatih model sehingga mampu menghasilkan performa yang optimal dalam mengekstraksi informasi dari suatu kumpulan data. Pada dasarnya, tujuan utama *machine learning* adalah membangun model yang dapat merepresentasikan pola-pola yang terdapat dalam data.(Sidik & Ansawarman, 2022)

Machine Learning merupakan bagian dari kecerdasan buatan (*Artificial Intelligence*) yang banyak dikembangkan dan dimanfaatkan untuk menyelesaikan berbagai permasalahan di berbagai bidang. Pendekatan ini bekerja dengan memanfaatkan data untuk membangun model yang mampu memberikan solusi atau prediksi terhadap suatu masalah. Secara umum, algoritma dalam *machine learning* dibagi menjadi tiga kategori utama, yaitu *supervised learning*, *unsupervised learning*, dan *reinforcement learning*. Penerapan *machine learning* saat ini telah meluas ke berbagai sektor, seperti industri, teknologi, transportasi, hingga kesehatan. Di antara berbagai bidang tersebut, sektor medis menjadi salah satu yang paling dominan dalam pemanfaatan *machine learning*, terutama dalam membantu proses diagnosis, analisis data pasien, serta pengambilan keputusan klinis.(Roihan et al., 2020)

Machine Learning merupakan teknologi pembelajaran mesin yang sangat membantu dalam menyelesaikan berbagai permasalahan serta mempermudah proses kerja di berbagai bidang, khususnya di sektor kesehatan. Dalam lingkungan rumah sakit, penerapan *machine learning* dapat membantu tenaga medis dan dokter dalam melakukan diagnosis penyakit secara lebih cepat dan efisien. Sebagai contoh, dokter dapat memanfaatkan sistem berbasis *machine learning* untuk membantu mendeteksi penyakit jantung dalam waktu yang lebih singkat tanpa memerlukan proses yang terlalu lama. Tidak hanya mempermudah pekerjaan dokter, teknologi ini juga memberikan manfaat besar bagi tenaga medis lainnya sehingga proses pelayanan kesehatan menjadi lebih efektif. Selain itu, *machine learning* juga berperan penting dalam proses klasifikasi penyakit, seperti mengidentifikasi jenis penyakit melalui hasil citra medis atau gambar dengan tingkat akurasi yang lebih optimal.(Fangatulo Dodo Telaumbanua et al., 2019).

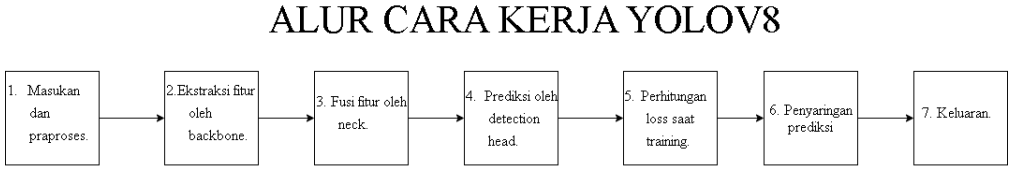
2.3YOLOv8

YOLOv8 (*You Only Look Once* versi 8) merupakan model terbaru dari keluarga YOLO yang dikembangkan oleh *Ultralytics*. Model ini menghadirkan sejumlah pembaruan yang cukup signifikan dibandingkan versi sebelumnya, seperti YOLOv5, baik dari segi arsitektur maupun kemudahan dalam proses pengembangan. Sejak pertama kali diperkenalkan pada tahun 2015, metode YOLO telah dikenal luas sebagai salah satu pendekatan *object detection* yang memiliki tingkat akurasi tinggi dengan ukuran model yang relatif ringan. Keunggulan tersebut menjadikan YOLO banyak digunakan dalam berbagai aplikasi berbasis pengolahan citra, termasuk dalam bidang penelitian dan industri.(Cahyanti, 2023)

YOLOv8 merupakan salah satu versi terbaru dari algoritma *You Only Look Once* (YOLO) yang dikembangkan oleh Ultralytics. Model ini menghadirkan berbagai peningkatan dibandingkan versi sebelumnya, baik dari sisi arsitektur maupun performa, seperti efisiensi komputasi yang lebih baik dan kemampuan deteksi objek yang lebih akurat. Salah satu perbedaan penting pada YOLOv8 adalah penggunaan pendekatan *anchor-free*, yang menyederhanakan proses prediksi dibandingkan metode sebelumnya yang masih berbasis *anchor*. Arsitektur YOLOv8 secara umum terdiri dari tiga bagian utama, yaitu *backbone*, *neck*, dan

head. Bagian *backbone* berfungsi untuk mengekstraksi fitur dari citra input menggunakan jaringan yang telah dioptimalkan. Selanjutnya, bagian *neck* bertugas menggabungkan dan menyempurnakan fitur tersebut melalui mekanisme seperti *feature pyramid*, sehingga informasi dari berbagai skala dapat dimanfaatkan. Terakhir, bagian *head* digunakan untuk menghasilkan prediksi akhir, seperti lokasi objek (bounding box), klasifikasi objek, serta tingkat kepercayaan terhadap deteksi yang dilakukan.(Aziz et al., 2023)

2.3.1 Cara Kerja YOLOv8



Gambar 2. 7 Alur Cara Kerja YOLOv8

Cara kerja YOLOv8 dalam penelitian ini dibedakan menjadi proses pelatihan dan proses inferensi. Pada pelatihan, citra beranotasi digunakan untuk menghitung kesalahan prediksi dan memperbarui bobot. Pada inferensi, bobot best.pt digunakan untuk menghasilkan bounding box, kelas, dan confidence tanpa memperbarui bobot. Tahapannya adalah sebagai berikut:

1. Masukan dan praproses.

   Citra digital dibaca sebagai tiga kanal warna, yaitu Red, Green, dan Blue (RGB). Setiap piksel mempunyai nilai intensitas pada rentang 0–255. Sebelum masuk ke jaringan, nilai piksel dinormalisasi ke rentang 0–1.
2. Ekstraksi fitur oleh backbone.

   Lapisan convolution menangkap pola lokal, blok C2f menggabungkan fitur lintas jalur, dan SPPF memperluas receptive field agar konteks objek pada ukuran berbeda dapat dipelajari.

   Pada tahap awal backbone, blok Conv menerima tensor citra dan melakukan convolution. Dalam implementasi Ultralytics, blok Conv terdiri dari operasi convolution, Batch Normalization, dan aktivasi SiLU. Convolution mengubah nilai piksel menjadi feature map dengan mempelajari pola lokal seperti tepi, tekstur, dan perubahan intensitas.

Setelah convolution, feature map diteruskan ke C2f untuk menggabungkan informasi fitur dari beberapa jalur, kemudian SPPF memperluas receptive field melalui pooling bertahap sehingga konteks objek pada area yang lebih luas dapat dipelajari.

3. Fusi fitur oleh neck.

Fitur dari beberapa tingkat resolusi digabungkan. Fitur resolusi tinggi membantu lokalisasi jerawat kecil, sedangkan fitur resolusi rendah membawa informasi semantik yang lebih kuat.

Feature map hasil backbone diteruskan ke neck. Neck menggabungkan informasi fitur dari resolusi yang berbeda menggunakan jalur top-down dan bottom-up.

4. Prediksi oleh detection head.

Head anchor-free menghasilkan koordinat bounding box b = (x_c, y_c, w, h) dan skor kelas untuk setiap kandidat objek. Cabang klasifikasi dan regresi bbox diproses terpisah.

Feature map dari neck diteruskan ke detection head. YOLOv8 menggunakan detection head anchor-free dan decoupled. Head menghasilkan prediksi kelas dan regresi bounding box tanpa menggunakan anchor box yang telah ditentukan sebelumnya.

Tahap berikutnya adalah proses decoding bounding box, penentuan sampel positif, perhitungan loss pada training, dan penyaringan prediksi pada inference yang dijelaskan pada subbab berikutnya.

5. Perhitungan loss saat training.

Total loss menggabungkan box loss, classification loss, dan Distribution Focal Loss. DFL memodelkan lokasi batas bbox sebagai distribusi sehingga regresi lokasi dapat dipelajari lebih halus

6. Penyaringan prediksi.

Kandidat dengan confidence di bawah threshold dibuang. Kandidat yang bertumpang tindih kemudian diproses dengan Non-Maximum Suppression berdasarkan IoU agar satu objek tidak menghasilkan banyak bbox.

7. Keluaran.

Sistem mengembalikan koordinat bbox, label Blackhead, Whitehead, Papula, Pustula, atau Nodul, serta confidence 0–1. Aplikasi Streamlit memvisualisasikan ketiga informasi tersebut pada citra.

2.3.1.1 Perhitungan Yolov8

Perhitungan YOLOv8 digunakan untuk memberikan gambaran matematis mengenai proses pengolahan citra hingga menghasilkan keluaran deteksi objek. Perhitungan ini melengkapi penjelasan mengenai cara kerja YOLOv8 dengan menunjukkan bagaimana data citra diproses menjadi *feature map* dan selanjutnya digunakan untuk menghasilkan kandidat deteksi..

Pada tahap awal, citra diproses melalui *backbone* untuk mengekstraksi fitur. Salah satu operasi utama yang digunakan adalah konvolusi, yaitu proses perkalian antara nilai pada citra atau *feature map* dengan bobot kernel pada setiap posisi tertentu. Hasil dari operasi tersebut berupa *feature map* yang merepresentasikan karakteristik visual dari citra. Secara matematis, operasi konvolusi dapat dinyatakan sebagai berikut:

$$S(i,j,k) = \sum_{m}\sum_{n}\sum_{c} X\,(i+m, j+n, c)W(m,n,c,k) + b_k \quad (1)$$

dengan X merupakan *feature map* masukan, merupakan bobot kernel, b_k merupakan *bias*, C menunjukkan kanal, dan m dan n menunjukkan posisi elemen kernel, sedangkan i dan j menunjukkan posisi kernel pada *feature map*. Nilai $S(i,j,k)$ merupakan nilai keluaran pada kanal ke-. k.

Ukuran *feature map* yang dihasilkan setelah operasi konvolusi dapat ditentukan berdasarkan ukuran masukan, kernel, *padding*, dan *stride*. Persamaan yang digunakan adalah:

$$H_{\text{out}} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1$$

$$W_{\text{out}} = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1 \quad (2)$$

Dengan H dan W adalah tinggi dan lebar input, K adalah ukuran kernel, P adalah padding, dan S adalah stride. Perhitungan ini menjelaskan bagaimana ukuran feature map berubah setelah convolution.

Untuk memberikan gambaran perhitungan yang lebih sederhana, operasi konvolusi dapat direpresentasikan menggunakan potongan matriks berukuran 5 × 5 piksel dan kernel 3 × 3. Potongan matriks tersebut digunakan sebagai contoh untuk memperlihatkan proses pergeseran (*sliding*) kernel pada citra dan perhitungan nilai *feature map*. Nilai kernel pada contoh perhitungan merupakan nilai ilustrasi dan bukan bobot aktual YOLOv8, karena bobot aktual model diperoleh melalui proses pelatihan (*training*).

Hasil perhitungan tersebut selanjutnya menjadi dasar untuk proses *decoding bounding box*, perhitungan IoU, *classification loss*, *total loss*, serta proses penyaringan hasil prediksi. Pembahasan mengenai formulasi koordinat *bounding box*, IoU, loss, dan penyaringan prediksi dijelaskan pada subbab berikutnya.

2.3.1.1.1 Formulasi Prediksi, Loss, dan Penyaringan

Tabel 2. 1 Keterangan Sistem Koordinat dan Parameter *Bounding Box*

No.	Simbol	Parameter	Keterangan
1.	x	Sumbu X	Menunjukkan posisi horizontal pada citra, yaitu arah dari kiri ke kanan. Nilai X semakin besar ketika posisi semakin ke kanan.
2.	y	Sumbu Y	Menunjukkan posisi vertikal pada citra, yaitu arah dari atas ke bawah. Nilai Y semakin besar ketika posisi semakin ke bawah.

No.	Simbol	Parameter	Keterangan
3.	(0,0)	Titik awal koordinat	Titik koordinat yang berada pada sudut kiri atas citra.
4.	x_c	Pusat *bounding box* pada sumbu X	Menunjukkan posisi titik pusat *bounding box* pada arah horizontal.
5.	y_c	Pusat *bounding box* pada sumbu Y	Menunjukkan posisi titik pusat *bounding box* pada arah vertikal.
6.	w	Lebar *bounding box*	Menunjukkan ukuran *bounding box* dari sisi kiri ke sisi kanan objek.
7.	h	Tinggi *bounding box*	Menunjukkan ukuran *bounding box* dari sisi atas ke sisi bawah objek.
8.	$x_{\text{center,pixel}}$	Koordinat pusat pada sumbu X	Posisi pusat *bounding box* pada arah horizontal dalam satuan piksel.
9.	$y_{\text{center,pixel}}$	Koordinat pusat pada sumbu Y	Posisi pusat *bounding box* pada arah vertikal dalam satuan piksel.
10.	w_{pixel}	Lebar dalam piksel	Lebar *bounding box* yang dihitung dalam satuan piksel.
11.	h_{pixel}	Tinggi dalam piksel	Tinggi *bounding box* yang dihitung dalam satuan piksel.
12.	W	Lebar citra	Lebar keseluruhan citra dalam satuan piksel.
13.	H	Tinggi citra	Tinggi keseluruhan citra dalam satuan piksel.

Bounding box hasil prediksi dinyatakan sebagai b = (x_c, y_c, w, h), dengan x_c dan y_c sebagai koordinat pusat serta w dan h sebagai lebar dan tinggi. Pada format label YOLO, keempat nilai dinormalisasi terhadap lebar dan tinggi citra sehingga berada pada rentang 0–1.

Untuk mengubah koordinat bounding box dari satuan piksel menjadi koordinat ternormalisasi, digunakan persamaan:

$$\begin{aligned} x_c &= \frac{x_{\text{pixel}}}{W} \\ y_c &= \frac{y_{\text{pixel}}}{H} \\ w &= \frac{w_{\text{pixel}}}{W} \\ h &= \frac{h_{\text{pixel}}}{H} \end{aligned} \qquad (3)$$

Sebaliknya, untuk memperoleh kembali koordinat dalam satuan piksel dari nilai yang telah dinormalisasi, digunakan:

$$\begin{aligned} x_{\text{center,pixel}} &= x_c \times W \\ y_{\text{center,pixel}} &= y_c \times H \\ w_{\text{pixel}} &= w \times W \\ h_{\text{pixel}} &= h \times H \end{aligned} \qquad (4)$$

Selanjutnya, setelah koordinat *bounding box* diperoleh dalam satuan piksel, tingkat kesesuaian antara *bounding box* hasil prediksi dan *bounding box* sebenarnya (*ground truth*) dapat dihitung menggunakan metrik Intersection over Union (IoU). IoU digunakan untuk mengukur seberapa besar daerah *bounding box* hasil prediksi yang bertumpang tindih dengan daerah *ground truth*. Nilai IoU dihitung menggunakan persamaan berikut:

a) Intersection over Union (IoU) detection head

$$IoU(B_p, B_{gt}) = \frac{|B_p \cap B_{gt}|}{|B_p \cup B_{gt}|} \qquad (5)$$

Keterangan:

B_p: bounding box hasil prediksi model.

B_{gt}: bounding box sebenarnya dari anotasi (*ground truth*).

$B_p \cap B_{gt}$: luas daerah yang saling bertumpuk.

$B_p \cup B_{gt}$: luas gabungan kedua kotak.

Nilai IoU berada antara 0 sampai 1:

IoU = 0: kotak prediksi tidak bertumpuk dengan anotasi.

IoU mendekati 1: kotak prediksi semakin sesuai.

IoU = 1: kotak prediksi sama persis dengan anotasi.

Luas gabungan (*union*) diperoleh dengan menjumlahkan luas *bounding box* prediksi dan *ground truth*, kemudian dikurangi dengan luas daerah yang saling bertumpuk agar area yang sama tidak dihitung dua kali. Secara matematis, luas gabungan dapat dinyatakan sebagai:

$$\left|B_p \cup B_{gt}\right| = \left|B_p\right| + \left|B_{gt}\right| - \left|B_p \cap B_{gt}\right|$$

Setelah menghitung IoU maka selanjutnya mencari CLoU dengan persamaan:

$$CIoU = IoU - \frac{\rho^2(b,b_{gt})}{c^2} - \alpha v \qquad (6)$$

Setelah menemukan nilai CLoU, maka selanjutnya mencari nilai Closs dengan persamaan:

$$L_{CIoU} = 1 - CIoU \qquad (7)$$

Kemudian hasil dari persamaan diatas nantinya akan digunakan dalam persamaan Total Loss.

b) Binary Cross-Entropy (BCE)

Classification loss digunakan untuk mengukur kesalahan antara nilai kelas sebenarnya dan probabilitas kelas yang diprediksi oleh model. Pada proses klasifikasi, salah satu fungsi kerugian yang digunakan adalah *Binary Cross-Entropy* (BCE). BCE menghitung perbedaan antara target kelas dan probabilitas prediksi. Persamaan BCE dinyatakan sebagai berikut:

$$L_{\text{BCE}} = -[y \log(p) + (1 - y) \log(1 - p)] \qquad (8)$$

Keterangan:

- L_{BCE} : nilai *classification loss*;
- y : nilai target kelas, yaitu 0 atau 1;
- p : probabilitas prediksi model terhadap kelas.

Nilai BCE akan semakin kecil ketika probabilitas prediksi model semakin mendekati nilai target kelas. Sebaliknya, kesalahan prediksi yang semakin besar akan menghasilkan nilai *loss* yang lebih tinggi.

c) Total Loss YOLOv8

$$L_{total} = \lambda_{box} L_{CIoU} + \lambda_{cls} L_{BCE} + \lambda_{dfl} L_{DFL} \qquad (9)$$

Rumus ini menggabungkan tiga jenis kesalahan model.

Keterangan:

L_{CIoU}: Mengukur kesalahan posisi, ukuran, rasio, dan jarak pusat bounding box

L_{BCE}: Mengukur kesalahan model dalam menentukan kelas jerawat

L_{DFL}: Membantu menentukan batas atau koordinat bounding box dengan lebih presisi

λ: Bobot yang mengatur pengaruh setiap komponen loss

Prediksi dinyatakan *true positive* apabila kelasnya sesuai dan IoU memenuhi ambang evaluasi τ, misalnya 0,50 pada mAP@0.5. Dalam NMS, prediksi diurutkan berdasarkan *confidence*; *bounding box* dengan skor tertinggi dipertahankan, sedangkan *bounding box* lain pada kelas yang sama ditekan apabila IoU-nya melebihi *threshold* NMS.

d) Backpropagation dan Pembaruan Bobot

Setelah nilai *total loss* diperoleh, proses *backpropagation* digunakan untuk menghitung gradien dari *loss* terhadap parameter model. Gradien tersebut kemudian digunakan oleh *optimizer* untuk memperbarui bobot model agar kesalahan prediksi dapat diminimalkan. Secara sederhana, pembaruan bobot dapat dinyatakan sebagai:

$$w_{\text{baru}} = w_{\text{lama}} - \eta \left(\frac{\partial L}{\partial w}\right) \qquad (10)$$

Keterangan:

1. w_{baru} : bobot setelah diperbarui;
2. w_{lama}: bobot sebelum diperbarui;
3. η *: learning rate*;
4. $\frac{\partial L}{\partial w}$: gradien *loss* terhadap bobot.

2.3.1.1.2 Penentuan Sampel Positif dengan Task-Aligned Assigner

Pada pelatihan deteksi objek, model harus menentukan titik kandidat mana yang bertanggung jawab terhadap setiap ground truth. Implementasi YOLOv8 menggunakan Task-Aligned Assigner (TAL). TAL tidak hanya melihat kedekatan spasial, tetapi menggabungkan skor kelas s dan IoU u sehingga kandidat yang baik secara klasifikasi sekaligus lokalisasi memperoleh prioritas. Metrik alignment dirumuskan sebagai berikut:

$$A = s^{\alpha} \times u^{\beta} \qquad (11)$$

Pada YOLOv8, α = 0,5 dan β = 6,0. Untuk setiap *ground truth*, kandidat yang pusatnya berada di dalam *bounding box* diurutkan berdasarkan A, lalu kandidat top-k dipilih sebagai sampel positif. Pangkat β yang lebih besar membuat kualitas lokalisasi memiliki pengaruh kuat.

2.4Confusion Matrix

Confusion matrix merupakan metode evaluasi yang digunakan untuk mengukur kinerja model klasifikasi dengan membandingkan hasil prediksi model terhadap kelas aktual. *Confusion matrix* memberikan informasi mengenai jumlah prediksi yang benar dan salah melalui empat komponen, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Komponen tersebut menjadi dasar dalam menghitung berbagai metrik evaluasi, seperti *accuracy*, *precision*, *recall*, dan *F1-score*, sehingga kemampuan model dalam membedakan setiap kelas dapat diketahui secara lebih terperinci(Sathyanarayanan & Tantri, 2024).



Gambar 2. 8 *Confusion Matrix*

1. *Accuracy*

Accuracy atau akurasi menunjukkan proporsi keseluruhan prediksi yang berhasil dilakukan dengan benar oleh model. Pada YOLOv8, nilai ini menggambarkan ketepatan model dalam mendeteksi objek jerawat maupun mengenali bagian yang bukan objek jerawat. Akurasi dihitung menggunakan persamaan berikut:

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \qquad (12)$$

Keterangan:

a.) TP : True positive, artinya model memprediksi benar kelas positif.
b.) TN : True negative, artinya model memprediksi benar kelas negatif.
c.) FP : False positive, artinya model salah memprediksi (didprediksi positif, padahal aslinya negatif).
d.) FN : False positive, artinya model salah memprediksi (didprediksi negatif, padahal aslinya postif).

Nilai akurasi yang semakin mendekati 1 menunjukkan bahwa semakin banyak data yang diprediksi dengan benar. Namun, akurasi dapat memberikan hasil yang kurang representatif apabila jumlah data pada setiap kelas tidak seimbang

2. Precision *(Positive Predictive Value)*

Precision atau *Positive Predictive Value* menunjukkan proporsi objek yang benar-benar merupakan jerawat dari seluruh objek yang diprediksi sebagai jerawat oleh model YOLOv8. Metrik ini digunakan untuk mengetahui tingkat ketepatan

model dalam menghasilkan prediksi positif. *Precision* dihitung menggunakan persamaan berikut:

$$Precision = \frac{TP}{TP+FP} \qquad (13)$$

Keterangan:

a.) TP : True positive, artinya Data positif yang diprediksi benar oleh model
b.) FP : False positive, artinya Data negatif yang diprediksi salah sebagai positif oleh model

Nilai *precision* yang tinggi menunjukkan bahwa model memiliki jumlah *false positive* yang rendah. Artinya, sebagian besar objek yang dideteksi sebagai jerawat benar-benar sesuai dengan anotasi pada data aktual

3. *Recall (True Positive Rate)*

Recall atau *True Positive Rate* menunjukkan kemampuan model YOLOv8 dalam mendeteksi seluruh objek jerawat yang sebenarnya terdapat pada citra. *Recall* dihitung dengan membandingkan jumlah objek jerawat yang berhasil dideteksi dengan seluruh objek jerawat aktual. Rumus *recall* adalah sebagai berikut:

$$Recall = \frac{TP}{TP+FN} \qquad (14)$$

Keterangan:

a.) TP : True positive, artinya data positif yang diprediksi benar sebagai positif.
b.) FN : False positive, artinya data positif yang diprediksisalah sebagai negatif.

Nilai *recall* yang tinggi menunjukkan bahwa model memiliki jumlah *false negative* yang rendah. Dengan demikian, hanya sedikit objek jerawat yang tidak berhasil terdeteksi oleh model

4. F1-*Score*

F1-score merupakan rata-rata harmonik dari *precision* dan *recall* yang digunakan untuk menilai keseimbangan antara ketepatan prediksi dan kemampuan

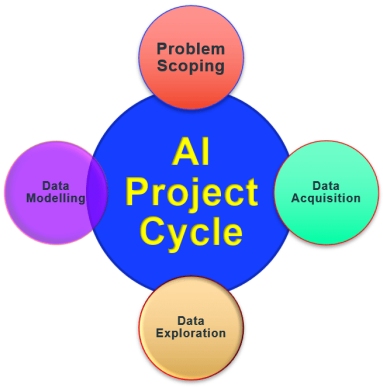
model dalam mendeteksi objek. *F1-score* dihitung menggunakan persamaan berikut:

$$F1\text{-}Score = 2\left(\frac{Precision \times Recall}{Precision + Recall}\right) \qquad (15)$$

Nilai *F1-score* berada pada rentang 0 sampai 1. Nilai yang semakin mendekati 1 menunjukkan bahwa model YOLOv8 memiliki keseimbangan yang semakin baik antara *precision* dan *recall*. Metrik ini sesuai digunakan ketika kesalahan *false positive* dan *false negative* perlu dipertimbangkan secara bersamaan.

Setelah pembahasan *confusion matrix* sebagai salah satu metode untuk menganalisis hasil prediksi model, diperlukan pemahaman mengenai tahapan pengembangan sistem kecerdasan buatan secara keseluruhan. Pengembangan model tidak hanya mencakup proses pemodelan dan evaluasi, tetapi juga melibatkan tahapan lain, mulai dari menentukan permasalahan, mengumpulkan data, memahami dan mengeksplorasi data, membangun model, melakukan evaluasi, hingga menerapkan model. Rangkaian tahapan tersebut diperlukan agar proses pengembangan sistem kecerdasan buatan dapat dilakukan secara terstruktur dan sesuai dengan tujuan yang telah ditetapkan. Oleh karena itu, pembahasan selanjutnya menjelaskan AI Project Cycle sebagai kerangka tahapan yang digunakan dalam pengembangan proyek kecerdasan buatan.

2.5 AI *Project Cycle*



Gambar 2. 9 *AI Project Cycle*

AI *Project Cycle* merupakan suatu tahapan atau siklus yang digunakan dalam proses pengembangan proyek berbasis *Artificial Intelligence*. Siklus ini berfungsi sebagai panduan sistematis dalam merancang, membangun, hingga mengevaluasi solusi yang dikembangkan, sehingga dapat membantu dalam menyelesaikan berbagai permasalahan dengan memanfaatkan teknologi kecerdasan buatan (Aurelia et al., 2023). *AI Project Cycle* terdiri dari beberapa tahapan yang saling berkaitan dalam proses pengembangan solusi berbasis *Artificial Intelligence*. Tahapan-tahapan tersebut meliputi:

2.5.1 Problem Scoping

Problem Scoping adalah tahap awal dalam pengembangan proyek *Artificial Intelligence* dimulai dengan mendefinisikan permasalahan secara jelas sebagai dasar utama dalam pelaksanaan proyek. Penentuan masalah yang tepat menjadi sangat penting karena akan mempengaruhi arah dan tujuan dari solusi yang akan dikembangkan. Salah satu cara sederhana untuk melakukan *problem scoping* adalah dengan mengidentifikasi unsur *who*, *what*, *where*, dan *why*, sehingga permasalahan dapat dipahami secara lebih terstruktur dan menyeluruh.

2.5.2 Data Acquisition

Kemudian tahap selanjutnya adalah tahap *data acquisition* merupakan proses pengumpulan data yang menjadi salah satu faktor kunci dalam keberhasilan proyek *Artificial Intelligence*. Kualitas data yang baik sangat berpengaruh terhadap hasil yang diperoleh, bahkan model sederhana sekalipun dapat menghasilkan performa yang optimal jika didukung oleh data yang berkualitas. Sebaliknya, penggunaan data yang kurang baik dapat menyebabkan hasil yang tidak akurat meskipun menggunakan model yang kompleks.

Dalam praktiknya, terdapat beberapa metode yang umum digunakan dalam proses pengumpulan data, antara lain membeli data dari pihak ketiga, mengonversi atau mentransformasikan data dari sumber yang sudah ada, berbagi atau bertukar data dengan pihak lain, serta mengumpulkan data secara langsung dari sumbernya.

2.5.3 Data Exploration

Data exploration merupakan tahap yang dilakukan untuk memahami, memeriksa, dan mempersiapkan karakteristik dataset sebelum digunakan dalam

proses pemodelan. Pada penelitian berbasis deteksi objek, tahap ini diperlukan untuk memastikan bahwa citra memiliki kualitas yang sesuai, objek telah diberikan anotasi dengan benar, ukuran citra telah disesuaikan, serta dataset memiliki variasi yang cukup untuk digunakan dalam proses pelatihan dan evaluasi model.

Dalam penelitian ini, proses *data exploration* dilakukan menggunakan Roboflow sebagai platform untuk pengelolaan dan persiapan dataset. Tahapan yang dilakukan meliputi pemeriksaan data, pelabelan (*labeling*), penyesuaian ukuran citra (*resizing*), augmentasi (*augmentation*), serta pembagian dataset menjadi data *training*, *validation*, dan *testing*. Seluruh tahapan tersebut dilakukan sebelum dataset digunakan pada proses pelatihan model YOLOv8.

Penggunaan Roboflow dalam tahap ini bertujuan untuk membuat proses persiapan dataset menjadi lebih terstruktur. Dataset yang telah melalui tahapan tersebut kemudian diekspor dalam format yang sesuai dengan kebutuhan YOLOv8 sehingga citra dan anotasinya dapat digunakan sebagai masukan pada tahap *modeling*.

2.5.3.1 Pemeriksaan Data

Tahap pertama dilakukan dengan memasukkan dataset citra ke dalam Roboflow. Citra yang digunakan diperiksa untuk memastikan bahwa data dapat digunakan dalam proses pelatihan. Pemeriksaan dilakukan terhadap keberadaan citra, kondisi visual citra, serta kesesuaian objek yang terdapat di dalam citra dengan objek yang menjadi target penelitian.

Pemeriksaan ini diperlukan karena kualitas dataset akan berpengaruh terhadap proses pembelajaran model. Citra yang memiliki kualitas kurang baik, objek yang tidak sesuai, atau data yang tidak dapat digunakan dapat menyebabkan model mempelajari pola yang kurang tepat. Oleh karena itu, sebelum dilakukan proses anotasi dan pengolahan lebih lanjut, dataset perlu diperiksa terlebih dahulu.

Setelah data dinyatakan sesuai, seluruh citra dikelola di dalam Roboflow sebagai dataset penelitian. Pada tahap ini, citra belum digunakan secara langsung untuk melakukan prediksi, tetapi dipersiapkan agar dapat digunakan pada tahap pelatihan YOLOv8.

2.5.3.2 Labelling

Setelah citra dimasukkan dan diperiksa, tahap berikutnya adalah melakukan pelabelan objek menggunakan fitur anotasi pada Roboflow. Pelabelan dilakukan secara manual dengan membuat *bounding box* pada objek yang menjadi target deteksi.

Bounding box digunakan untuk menunjukkan posisi dan area objek pada citra. Selain menentukan lokasi objek, setiap *bounding box* diberikan kelas sesuai dengan kategori objek yang telah ditentukan dalam penelitian.

Pada proses ini, *bounding box* diusahakan mencakup objek secara tepat dan tidak memasukkan area yang tidak termasuk bagian objek. Ketepatan anotasi diperlukan karena hasil pelabelan akan digunakan sebagai *ground truth* pada saat model YOLOv8 mempelajari hubungan antara citra masukan dengan lokasi dan kelas objek.

Hasil pelabelan pada Roboflow kemudian menjadi anotasi yang digunakan dalam dataset. Anotasi tersebut nantinya dikonversikan ke format yang sesuai dengan YOLOv8 ketika dataset diekspor.

2.5.3.3 Resizing Image

Setelah proses pelabelan, citra disiapkan dengan ukuran yang sesuai dengan kebutuhan model. Penyesuaian ukuran atau *resizing* dilakukan menggunakan Roboflow agar citra yang digunakan dalam proses pelatihan memiliki ukuran masukan yang konsisten.

Perbedaan ukuran citra dapat menyebabkan proses pemrosesan menjadi tidak seragam. Oleh karena itu, *resizing* digunakan untuk menyesuaikan dimensi citra dengan konfigurasi yang akan digunakan pada YOLOv8.

Dalam proses ini, penyesuaian ukuran tidak hanya diterapkan terhadap citra, tetapi informasi anotasi juga harus tetap mengikuti perubahan posisi dan ukuran objek pada citra. Dengan demikian, *bounding box* tetap menunjukkan lokasi objek yang sesuai setelah citra mengalami perubahan ukuran.

2.5.3.4 Augmentation

Tahap berikutnya adalah augmentasi data yang dilakukan menggunakan Roboflow. Augmentasi merupakan proses menghasilkan variasi dari citra yang tersedia dengan memberikan transformasi tertentu terhadap data.

Tujuan augmentasi adalah meningkatkan keragaman data pelatihan sehingga model tidak hanya mempelajari objek berdasarkan satu kondisi citra tertentu. Variasi tersebut dapat membantu model mempelajari karakteristik objek secara lebih baik dan mengurangi ketergantungan model terhadap kondisi tertentu pada dataset.

Dalam penelitian ini, augmentasi dilakukan terhadap data yang digunakan untuk pelatihan. Transformasi yang diberikan melalui Roboflow menghasilkan variasi citra dari dataset asli, sementara anotasi *bounding box* disesuaikan dengan perubahan citra yang dihasilkan.

Hal yang penting dalam proses ini adalah data testing dipisahkan terlebih dahulu sebelum proses augmentasi dilakukan. Dengan demikian, data *testing* tidak ikut digunakan untuk menghasilkan variasi data pelatihan. Pemisahan tersebut bertujuan menjaga agar data pengujian tetap menjadi data yang tidak digunakan dalam proses pembelajaran model.

2.5.4 Modeling

Setelah menemukan informasi yang dibutuhkan, maka tahap selanjutnya adalah tahap *modelling* merupakan proses pembangunan model dalam proyek *Artificial Intelligence* dengan memilih algoritma atau teknik yang sesuai dengan permasalahan. Pada tahap ini, data yang telah dipahami sebelumnya digunakan untuk melatih model agar dapat menghasilkan prediksi atau keputusan yang tepat.

2.5.5 Evaluation

Setelah membuat atau merancang model maka akan dilakukan tahap *evaluation,* yang merupakan proses untuk mengukur kinerja model yang telah dibuat. Pada tahap ini, model diuji untuk mengetahui tingkat akurasi serta kelebihan dan kekurangannya. Hasil evaluasi ini penting sebagai dasar untuk melakukan perbaikan agar performa model dapat terus ditingkatkan.

2.5.6 Deployment

Tahap terakhir pada siklus ini adalah tahap *deployment,* yang merupakan tahap akhir dalam proyek *Artificial Intelligence*, yaitu proses penerapan model ke dalam lingkungan nyata. Pada tahap ini, model yang telah dibuat mulai digunakan untuk membantu pengambilan keputusan atau menyelesaikan permasalahan secara langsung. Oleh karena itu, tahap ini memerlukan perhatian khusus karena hasil dari sistem dapat berdampak pada pengguna.

Berdasarkan tahapan *AI Project Cycle* yang telah dijelaskan, pengembangan sistem kecerdasan buatan tidak berhenti pada tahap pembangunan dan penerapan model. Model yang telah dikembangkan perlu diketahui tingkat keberhasilannya dalam menghasilkan prediksi sesuai dengan data yang diberikan. Oleh karena itu, diperlukan tahap evaluasi untuk mengukur kinerja model berdasarkan hasil prediksi yang diperoleh. Evaluasi dilakukan dengan membandingkan hasil prediksi model terhadap kondisi sebenarnya sehingga dapat diketahui tingkat ketepatan dan kemampuan model dalam melakukan klasifikasi maupun deteksi objek. Dengan demikian, tahap evaluasi menjadi bagian penting untuk memastikan bahwa model yang dikembangkan dapat memberikan hasil yang sesuai dengan tujuan penelitian.

2.6Evaluasi

Evaluasi merupakan proses untuk menilai kinerja model *machine learning* yang telah dibangun. Pada tahap ini, model diuji menggunakan data tertentu untuk mengetahui sejauh mana kemampuan model dalam menghasilkan prediksi atau klasifikasi yang akurat. Evaluasi dilakukan untuk mengidentifikasi kelebihan dan kekurangan model, sehingga dapat diketahui apakah model tersebut sudah layak digunakan atau masih memerlukan perbaikan (Hidayat & Subekti, 2025).

Dalam proses evaluasi, digunakan berbagai metrik pengukuran seperti *accuracy*, *precision*, *recall*, *F1-score*, serta *mean squared error* (MSE) atau *R-squared* (R^2) sesuai dengan jenis permasalahan yang dihadapi. Metrik ini digunakan untuk memberikan gambaran yang objektif terhadap performa model dalam mengolah data dan menghasilkan prediksi (Idris & Pontoiyo, 2025)

Selain itu, evaluasi juga berperan penting dalam membandingkan beberapa algoritma untuk menentukan metode yang paling optimal. Proses ini membantu peneliti dalam memilih model terbaik berdasarkan hasil pengujian, sehingga dapat meningkatkan akurasi dan kualitas sistem yang dikembangkan (Nugraha et al., 2025).

2.7 Penelitian Terdahulu

Penelitian terdahulu yang disajikan pada Tabel 2.1 menunjukkan bahwa berbagai model *deep learning* dalam ranah *computer vision*, mulai dari arsitektur R-CNN hingga seri YOLO, telah digunakan secara luas dalam tugas pendeteksian objek citra. Penelitian-penelitian tersebut menunjukkan bahwa algoritma YOLOv8 memiliki kinerja yang lebih unggul dalam hal akurasi dan kecepatan dibandingkan versi-versi sebelumnya karena adanya fitur deteksi multi-skala dan arsitektur *anchor-free*. Namun, belum banyak penelitian yang secara khusus menganalisis pengaruh variasi parameter teknis seperti rasio pembagian data (*training data split*) dan jumlah *epoch* pada klasifikasi jerawat yang difokuskan pada karakteristik wajah masyarakat Indonesia. Akibatnya, tujuan dari penelitian ini adalah untuk mengevaluasi dan menentukan konfigurasi optimal model YOLOv8 guna menghasilkan performa terbaik dalam mendeteksi serta mengklasifikasikan jenis jerawat, khususnya komedo terbuka, komedo tertutup, dan papula.

Tabel 2. 2 Penelitian Terdahulu dan *Research GAP*

No.	Penulis & Tahun	Judul Penelitian	Metode	Dataset	Hasil
1	Pratama et al. (2024)	Optimasi *Hyperparameter* pada YOLOv9 untuk Klasifikasi *Acne Vulgaris*	YOLOv9 (Arsitektur PGI)	2.500 citra klinis	YOLOv9 meningkatkan mAP sebesar 5,2% dibandingkan YOLOv8 pada lesi kecil.
2	Sari & Wijaya (2024)	Implementasi *Real-time Skin Analysis* menggunakan YOLOv8 pada *Mobile*	YOLOv8-Nano & Flutter	1.200 citra wajah remaja	Berhasil berjalan pada perangkat mobile dengan akurasi 89% dan latensi rendah.

No.	Penulis & Tahun	Judul Penelitian	Metode	Dataset	Hasil
3	Rahman et al. (2025)	Deteksi *Multitask* Jerawat dan Bekas Jerawat dengan YOLOv10	YOLOv10 (Anchor-free & NMS-free)	Dataset Gabungan (Kaggle & Klinik)	Mengurangi waktu inferensi hingga 30% dan lebih akurat membedakan jerawat aktif.
4	Lestari (2025)	Pengaruh Augmentasi GAN pada Akurasi Deteksi Jerawat	YOLOv8 + StyleGAN	500 citra asli (ekspansi ke 3.000)	Akurasi meningkat 6% pada kelas jerawat langka setelah augmentasi sintetis.
5	Handoko & Kusuma (2024)	Analisis Performa YOLOv8-seg untuk Segmentasi Lesi Jerawat	YOLOv8-Segmentation	1.500 citra dianotasi poligon	Mencapai 91% IoU, memberikan batas area jerawat yang lebih presisi dibanding bounding box.
6	Fitriani et al. (2025)	Deteksi Jerawat Zero-shot menggunakan Model YOLO-World	YOLO-World (Vision-Language)	Open-vocabulary skin dataset	Mampu mendeteksi jenis lesi baru tanpa training ulang dengan mAP 85%.
7	Aditya & Saputra (2024)	Optimasi YOLOv8-Nano untuk Deteksi Kulit pada Perangkat IoT	YOLOv8-Nano + Quantization	2.000 citra wajah	Ukuran model berkurang 75% dengan penurunan akurasi hanya 1,2%.
8	Wahyudi et al. (2025)	Integrasi Attention Mechanism pada YOLOv8 untuk Jerawat Kecil	YOLOv8 + SE-Block	Dataset Resolusi Tinggi (4K)	Peningkatan deteksi pada jerawat komedo (kecil) sebesar 7% mAP.
9	Ramadhan (2024)	Evaluasi Ketahanan YOLOv8 Terhadap Variasi Pencahayaan	YOLOv8 dengan Augmentasi Cahaya	1.800 citra variasi lux	Model tetap stabil pada kondisi cahaya rendah (indoor) dengan akurasi 82%.
10	Utami & Pratomo (2025)	Klasifikasi Jerawat Inflamasi Menggunakan	YOLOv8-X (*Extra Large)*	3.500 citra terverifi	Mencapai mAP tertinggi 94,5% untuk kelas Pustula

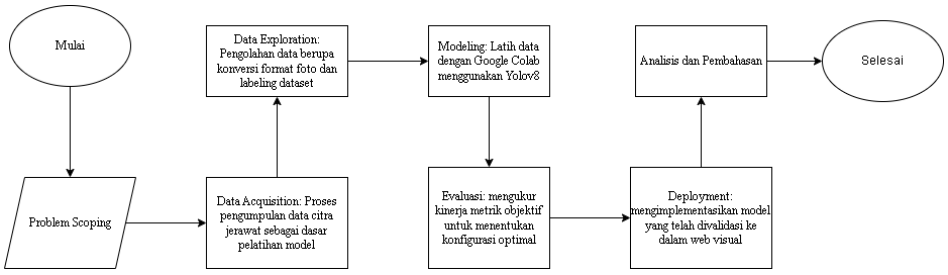
No.	Penulis & Tahun	Judul Penelitian	Metode	Dataset	Hasil
		YOLOv8-X *(Transfer Learning)*		kasi dokter	dan Nodul secara spesifik.

2.8GAP Analisis

Penelitian ini mengisi celah (*gap*) yang ada dalam literatur mengenai deteksi jerawat melalui beberapa pendekatan inovatif yang belum banyak dibahas secara mendalam dalam penelitian sebelumnya. Pertama, dari sisi teknis arsitektur, penelitian ini mengadopsi algoritma YOLOv8 yang menggunakan pendekatan *anchor-free* untuk menyederhanakan proses prediksi dan meningkatkan efisiensi komputasi dibandingkan model-model pendahulu yang masih berbasis *anchor*. Kedua, terdapat kesenjangan informasi mengenai optimalisasi parameter pelatihan, sehingga penelitian ini secara khusus berfokus pada analisis pengaruh variasi rasio pembagian data (*training data split*) dan jumlah *epoch* terhadap akurasi model, sebuah area yang diidentifikasi belum banyak dieksplorasi. Ketiga, riset ini melakukan lokalisasi objek dengan menggunakan citra wajah masyarakat Indonesia untuk memastikan hasil deteksi lebih relevan dengan karakteristik kulit lokal dibandingkan penggunaan *dataset* global. Terakhir, penelitian ini tidak hanya berhenti pada tahap pengujian model, melainkan berlanjut hingga tahap *deployment* berbasis web visual untuk mendeteksi jenis jerawat spesifik seperti komedo terbuka, komedo tertutup, dan papula, sehingga hasilnya dapat diakses secara praktis oleh masyarakat luas untuk menilai kondisi wajah secara objektif

BAB III
METODE PENELITIAN

3.1Tahap Penelitian



Gambar 3. 1 Diagram Alur *AI Project Cycle*

Metodologi penelitian ini mengikuti kerangka AI Project Cycle yang terdiri atas *problem scoping, data acquisition, data exploration, modelling, evaluation*, dan *deployment*. Urutan tersebut digunakan agar proses penelitian berlangsung sistematis, mulai dari perumusan masalah hingga penerapan model pada aplikasi. Alur penelitian ditunjukkan pada Gambar 3. 1.

3.2Problem Scoping

Tahap *problem scoping* dilakukan untuk merumuskan masalah, tujuan, batasan, dan keluaran sistem. Permasalahan utama penelitian adalah perlunya sistem yang dapat mendeteksi lokasi dan mengklasifikasikan jenis jerawat pada citra wajah secara otomatis. Objek penelitian dibatasi pada lima kelas, yaitu *Blackhead, Whitehead,* Papula, Pustula, dan Nodul. Sistem menghasilkan *bounding box*, label kelas, serta nilai *confidence* dan tidak digunakan sebagai alat diagnosis medis atau penentu tingkat keparahan jerawat.

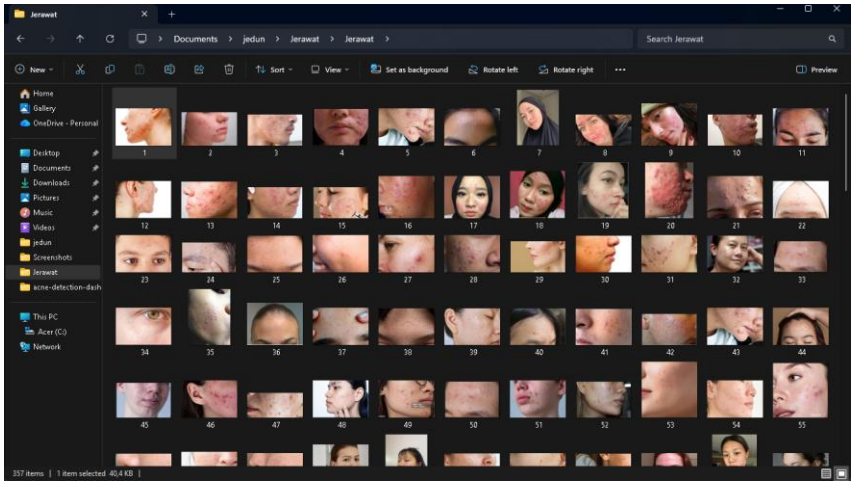
Tabel 3. 1 *Problem Scoping*

Pertanyaan	Jawaban
Apa tujuan dari hasil pengujian jenis jerawat yang dilakukan?	Penelitian ini bertujuan untuk menentukan faktor akurasi terhadap objek deteksi jerawat.
Siapa saja yang akan mendapatkan manfaat dari hasil penlitian ini?	Penelitian ini bermanfaat terhadap manusia dari kalangan muda maupun tua yang sedang mengalami masalah jerawat.
Dimana fokus penelitian ini dilakukan?	Penelitian ini difokuskan pada objek wajah masyarakat Indonesia yang mengalami permasalahan jerawat.
Mengapa menggunakan metode Yolov8 dalam penilitian ini?	Hal ini dikarenakan YOLOv8 memiliki tingkat akurasi yang tinggi dalam mendeteksi dan mengklasifikasikan objek berdasarkan berbagai referensi dan sumber literatur yang telah dipelajari.

3.3 Data Acquisition

Pada tahap data acquisition dilakukan pengumpulan citra yang digunakan sebagai bahan pelatihan, validasi, dan pengujian model. Data awal diperoleh dari repositori Kaggle dengan judul “7 masalah kulit Indonesia”. Dari dataset tersebut dipilih citra yang sesuai dengan lima kelas jerawat pada batasan penelitian, dengan jumlah sekurang-kurangnya 50 citra untuk setiap kelas.

Seluruh citra dikumpulkan dalam satu direktori kerja, kemudian diperiksa format, keterbacaan, dan kesesuaiannya dengan objek penelitian. Citra yang tidak relevan, rusak, atau duplikat dipisahkan agar tidak memengaruhi proses pelatihan. Data yang lolos pemeriksaan selanjutnya diimpor ke Roboflow untuk dikelola dan dianotasi.



Gambar 3. 2 Folder Citra yang sudah lolos verifikasi

Citra kemudian dikelompokkan berdasarkan kelas *Blackhead, Whitehead*, Papula, Pustula, dan Nodul. Pengelompokan ini mempermudah proses anotasi dan pemeriksaan konsistensi label. Contoh citra setiap kelas ditampilkan pada Tabel 3. 2.

Tabel 3. 2 Dataset Jerawat

Blackhead	Whiteheads	Nodul
		

Pustula	Papula
	

3.4 Data Exploration

Tahap data exploration bertujuan memahami karakteristik citra dan menyiapkan dataset agar memenuhi format masukan YOLOv8. Proses yang dilakukan meliputi pemeriksaan kualitas citra, pelabelan, *resizing, augmentasi*, dan pembagian dataset menjadi *training, validation*, serta *testing.* Data uji dipisahkan sebelum augmentasi untuk mencegah kebocoran data dan menjaga objektivitas evaluasi.

3.4.1 Labeling

Pelabelan dilakukan secara manual menggunakan Roboflow dengan membuat bounding box yang mengelilingi setiap objek jerawat. Label diberikan sesuai kelas objek, tidak memotong area jerawat, dan dibuat konsisten pada seluruh citra. Citra sebelum dan sesudah pelabelan ditunjukkan pada Gambar 3.3 dan Gambar 3.4.



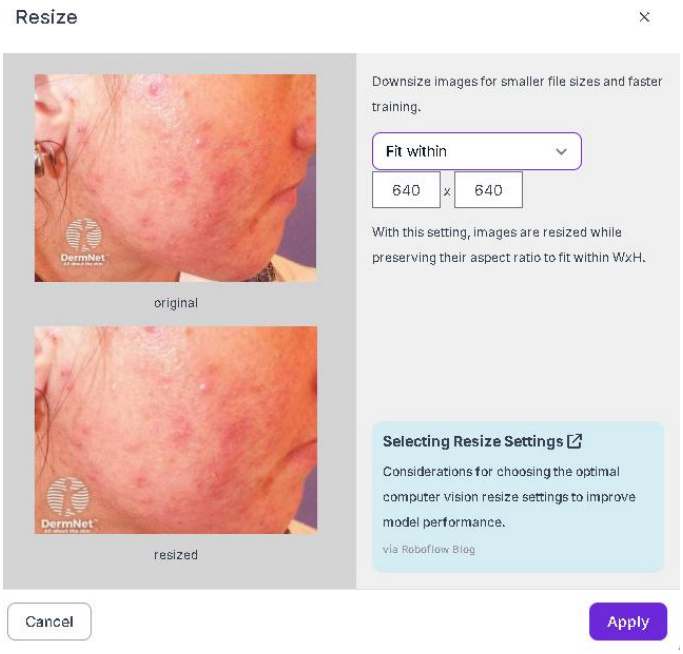
Gambar 3. 3 Citra Jerawat Sebelum pelabelan



Gambar 3. 4 Citra sesudah Pelabelan

3.4.2 Resizing Image:

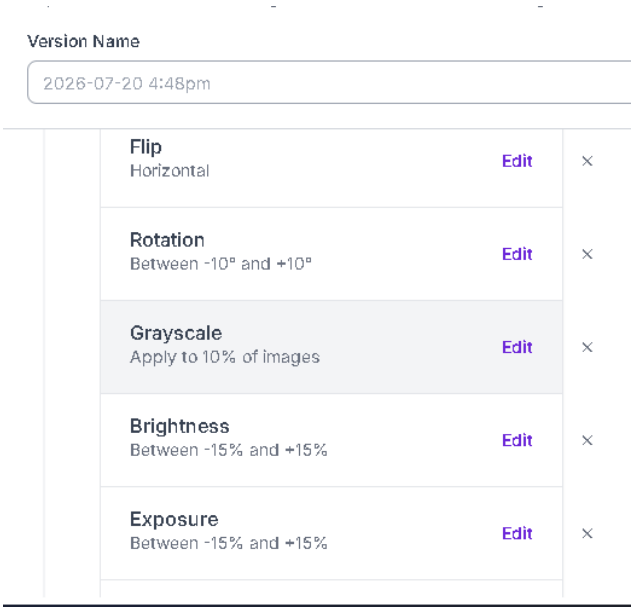
Seluruh citra diubah ke ukuran 640 × 640 piksel melalui Roboflow. Ukuran ini disesuaikan dengan parameter image size pada pelatihan YOLOv8 agar masukan model seragam dan kebutuhan komputasi tetap terkendali.



Gambar 3. 5 Proses Resizing Citra pada Roboflow

3.4.3 Augmentation

Augmentasi diterapkan hanya pada data training menggunakan teknik *crop* dan *flip*. Tujuannya adalah menambah variasi data serta meningkatkan kemampuan model menghadapi perubahan posisi dan komposisi citra. Data validation dan testing tidak diberi augmentasi agar hasil evaluasi menggambarkan performa model pada data yang tidak dimodifikasi.



Gambar 3. 6 Konfigurasi Augmentasi pada Roboflow

3.4.4 Rancangan Eksperimen

Penelitian merencanakan 12 pengujian yang menggabungkan empat variasi rasio pembagian data dan tiga variasi maksimum epoch, yaitu 80, 100, dan 120. Arsitektur YOLOv8s, ukuran citra 640 × 640 piksel, batch size 16, patience 20, dan prosedur evaluasi dibuat sama agar pengaruh konfigurasi dapat dibandingkan secara adil. Sebanyak 12 pengujian telah selesai.

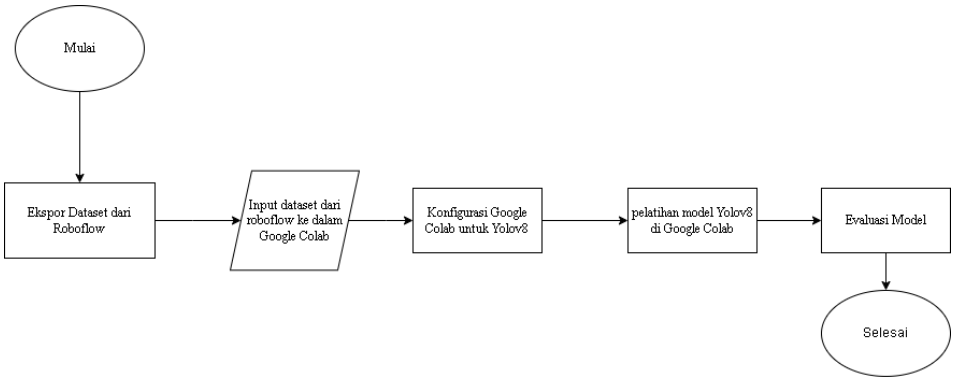
Tabel 3. 3 Rancangan Eksperimen Model YOLOv8

Uji	**Kelompok**	**Rasio Data**	**Epoch**	**Variabel Tetap**
1	Variasi rasio dan epoch	80:15:5	80	YOLOv8s, imgsz 640, batch 16, patience 20
2	Variasi rasio dan epoch	80:15:5	100	YOLOv8s, imgsz 640, batch 16, patience 20
3	Variasi rasio dan epoch	80:15:5	120	YOLOv8s, imgsz 640, batch 16, patience 20
4	Variasi rasio dan epoch	50:20:30	80	YOLOv8s, imgsz 640, batch 16, patience 20
5	Variasi rasio dan epoch	50:20:30	100	YOLOv8s, imgsz 640, batch 16, patience 20
6	Variasi rasio dan epoch	50:20:30	120	YOLOv8s, imgsz 640, batch 16, patience 20
7	Variasi rasio dan epoch	60:20:20	80	YOLOv8s, imgsz 640, batch 16, patience 20
8	Variasi rasio dan epoch	60:20:20	100	YOLOv8s, imgsz 640, batch 16, patience 20
9	Variasi rasio dan epoch	60:20:20	120	YOLOv8s, imgsz 640, batch 16, patience 20
10	Variasi rasio dan epoch	70:20:10	80	YOLOv8s, imgsz 640, batch 16, patience 20

Uji	Kelompok	Rasio Data	Epoch	Variabel Tetap
11	Variasi rasio dan epoch	70:20:10	100	YOLOv8s, imgsz 640, batch 16, patience 20
12	Variasi rasio dan epoch	70:20:10	120	YOLOv8s, imgsz 640, batch 16, patience 20

3.5 Modeling

Tahap modelling merupakan proses membangun model deteksi menggunakan YOLOv8 pada Google Colaboratory. Alur pemodelan dimulai dari memuat dataset, melakukan training, menyimpan hasil terbaik, dan menjalankan validasi. Rangkaian proses tersebut ditunjukkan pada Gambar 3. 7.



Gambar 3. 7 Flowchart Implementasi YOLOv8

3.5.1 Perhitungan pada Proses Modeling YOLOv8

Pada tahap pemodelan, proses perhitungan YOLOv8 dilakukan untuk menggambarkan bagaimana citra masukan diproses oleh model hingga menghasilkan prediksi objek. Perhitungan dimulai dari proses ekstraksi fitur pada bagian *backbone* menggunakan operasi konvolusi. Fitur yang diperoleh kemudian diteruskan ke bagian *neck* untuk menggabungkan informasi dari beberapa tingkat resolusi sehingga informasi objek berukuran kecil, sedang, maupun besar dapat dipertahankan. Selanjutnya, hasil ekstraksi dan penggabungan fitur diteruskan ke

detection head untuk menghasilkan prediksi kelas objek, koordinat *bounding box*, serta nilai *confidence*.

Dalam penelitian ini, perhitungan pada proses pemodelan tidak hanya menjelaskan proses ekstraksi fitur, tetapi juga mencakup tahapan perhitungan yang berkaitan dengan prediksi *bounding box*. Pada tahap tersebut digunakan koordinat *bounding box* hasil anotasi (*ground truth*) dan koordinat *bounding box* hasil prediksi model. Kedua *bounding box* tersebut digunakan untuk menghitung nilai Intersection over Union (IoU) sebagai ukuran tingkat kesesuaian antara lokasi objek yang diprediksi dengan lokasi objek sebenarnya.

Nilai IoU selanjutnya berkaitan dengan proses perhitungan *bounding box loss* pada saat pelatihan model. Selain itu, model juga menghitung *classification loss* untuk mengetahui kesalahan dalam memprediksi kelas objek dan *Distribution Focal Loss* untuk membantu meningkatkan ketepatan prediksi koordinat *bounding box*. Ketiga komponen tersebut kemudian dikombinasikan menjadi total loss yang digunakan sebagai dasar pembaruan bobot model melalui proses *backpropagation*.

Setelah proses pelatihan selesai, model digunakan pada tahap inferensi untuk menghasilkan prediksi pada citra baru. Pada tahap ini, model menghasilkan koordinat *bounding box*, kelas objek, dan nilai *confidence*. Nilai *confidence* kemudian digunakan dalam proses penyaringan prediksi sebelum dilakukan Non-Maximum Suppression (NMS). Dengan demikian, rangkaian perhitungan pada proses modeling YOLOv8 dalam penelitian ini meliputi operasi konvolusi, normalisasi koordinat *bounding box*, perhitungan IoU, perhitungan *loss*, pembaruan bobot, penentuan sampel positif, hingga proses inferensi.

3.5.2.1 Operasi Konvolusi pada Backbone

Untuk mengilustrasikan proses ekstraksi fitur secara komputasional, dilakukan perhitungan operasi konvolusi menggunakan potongan matriks dari citra penelitian. Citra yang digunakan dalam penelitian memiliki ukuran masukan 640 × 640 piksel. Karena matriks citra secara keseluruhan memiliki jumlah piksel yang sangat besar, perhitungan secara keseluruhan tidak ditampilkan dalam dokumen. Oleh karena itu,

digunakan potongan matriks berukuran 5 × 5 piksel yang diambil dari salah satu citra pada dataset penelitian. Ukuran 5 × 5 dipilih agar proses pergeseran (*sliding*) kernel berukuran 3 × 3 dapat ditunjukkan secara jelas.

$$S(i,j) = \sum_{m}\sum_{n} I\,(i+m, j+n)K(m,n)$$

Keterangan:

- $S(i,j)$: nilai *feature map* pada posisi ;
- I: matriks nilai piksel citra masukan;
- K : matriks kernel konvolusi;
- i,j : posisi pergeseran kernel pada citra;
- m,n : posisi elemen kernel.

Dari data citra yang digunakan, diperoleh tiga matriks 5 × 5 sebagai berikut:

a.) Saluran Red (R)

$$IR = \begin{bmatrix} 220 & 212 & 206 & 195 & 186 \\ 216 & 215 & 212 & 205 & 197 \\ 214 & 213 & 213 & 210 & 205 \\ 217 & 214 & 215 & 215 & 213 \\ 222 & 222 & 228 & 230 & 231 \end{bmatrix}$$

b.) Saluran Green (G):

$$IG = \begin{bmatrix} 115 & 110 & 105 & 94 & 85 \\ 118 & 118 & 115 & 108 & 101 \\ 122 & 121 & 122 & 119 & 115 \\ 130 & 128 & 132 & 132 & 132 \\ 143 & 144 & 152 & 157 & 158 \end{bmatrix}$$

c.) Saluran Blue (B):

$$IB = \begin{bmatrix} 129 & 123 & 119 & 108 & 99 \\ 131 & 129 & 126 & 119 & 112 \\ 137 & 132 & 131 & 128 & 124 \\ 147 & 139 & 140 & 140 & 139 \\ 162 & 158 & 164 & 168 & 170 \end{bmatrix}$$

Kernel 3 × 3 yang digunakan pada simulasi adalah:

$$K = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

Untuk posisi pertama, kernel ditempatkan pada bagian kiri atas matriks R sehingga diperoleh:

$$\begin{aligned} S_R(1,1) &= (220 \times 1) + (212 \times 1) + (206 \times 0) \\ &\quad +(216 \times 1) + (215 \times 1) + (212 \times 0) \\ &\quad +(214 \times 1) + (213 \times 1) + (213 \times 1) \\ &= 220 + 212 + 216 + 215 + 214 + 213 + 213 \\ &= 1503 \end{aligned}$$

Dengan proses *sliding* yang sama, diperoleh *feature map* saluran Red:

$$FR = \begin{bmatrix} 1503 & 1481 & 1446 \\ 1504 & 1497 & 1483 \\ 1530 & 1535 & 1542 \end{bmatrix}$$

Selanjutnya perhitungan pada saluran Green:

$$\begin{aligned} S_G(1,1) &= (115 \times 1) + (110 \times 1) + (105 \times 0) \\ &\quad +(118 \times 1) + (118 \times 1) + (115 \times 0) \\ &\quad +(122 \times 1) + (121 \times 1) + (122 \times 1) \\ &= 115 + 110 + 118 + 118 + 122 + 121 + 122 \\ &= 826 \end{aligned}$$

Hasil *feature map* saluran Green adalah:

$$FG = \begin{bmatrix} 826 & 810 & 778 \\ 869 & 868 & 860 \\ 940 & 956 & 973 \end{bmatrix}$$

Selanjutnya perhitungan pada saluran Blue:

$$\begin{aligned} S_B(1,1) &= (129 \times 1) + (123 \times 1) + (119 \times 0) \\ &\quad +(131 \times 1) + (129 \times 1) + (126 \times 0) \\ &\quad +(137 \times 1) + (132 \times 1) + (131 \times 1) \\ &= 129 + 123 + 131 + 129 + 137 + 132 + 131 \\ &= 912 \end{aligned}$$

Hasil *feature map* saluran Blue adalah:

$$FB = \begin{bmatrix} 912 & 888 & 855 \\ 955 & 937 & 923 \\ 1039 & 1032 & 1041 \end{bmatrix}$$

Setelah operasi konvolusi dilakukan pada ketiga saluran warna, nilai *feature map* akhir diperoleh dengan menggabungkan hasil dari saluran R, G, dan B pada posisi yang sama.

$$F_{\text{akhir}} = F_R + F_G + F_B$$

Untuk posisi pertama:

$$F_{\text{akhir}}(1,1) = 1503 + 826 + 912 = 3241$$

Dengan cara yang sama pada seluruh posisi, diperoleh:

$$F_{\text{akhir}} = \begin{bmatrix} 3241 & 3179 & 3079 \\ 3328 & 3302 & 3266 \\ 3509 & 3523 & 3556 \end{bmatrix}$$

Jadi, dari matriks citra RGB 5 × 5, setelah dilakukan operasi konvolusi menggunakan kernel 3 × 3, dihasilkan *feature map* berukuran 3 × 3.

3.5.2.2 Normalisasi bounding box

Sebelum digunakan dalam proses pelatihan, koordinat *bounding box* pada format YOLO dinyatakan dalam bentuk koordinat yang telah dinormalisasi terhadap ukuran citra. Karena citra yang digunakan memiliki ukuran 640 × 640 piksel, nilai koordinat ternormalisasi tersebut dapat dikonversi kembali ke koordinat piksel untuk mengetahui posisi dan ukuran *bounding box* pada citra.

$$x_c = \frac{x_{\text{pixel}}}{W}$$
$$y_c = \frac{y_{\text{pixel}}}{H}$$
$$w = \frac{w_{\text{pixel}}}{W}$$
$$h = \frac{h_{\text{pixel}}}{H}$$

Dengan W: 640 dan H: 640, diperoleh:

a. Koordinat pusat pada sumbu X

$$x_{\text{center}} = 0{,}40134375 \times 640 = 256{,}86 \approx 257 \text{ piksel}$$

b. Koordinat pusat pada sumbu Y

$$y_{\text{center,pixel}} = 0{,}465734375 \times 640 = 298{,}07 \approx 298 \text{ piksel}$$

c. Lebar bounding box

$$w_{\text{pixel}} = 0{,}70446875 \times 640 = 450{,}86 \text{ piksel}$$

d. Tinggi bounding box

$$h_{\text{pixel}} = 0{,}755796875 \times 640 = 483{,}71 \text{ piksel}$$

Dengan demikian, anotasi dengan class_id = 1 memiliki titik pusat *bounding box* pada sekitar koordinat (257, 298) piksel, dengan lebar sekitar 450,86 piksel dan tinggi sekitar 483,71 piksel. Perhitungan ini menunjukkan hubungan antara nilai koordinat yang disimpan pada format anotasi YOLO dengan posisi objek pada citra berukuran 640 × 640 piksel.

3.5.2.3 Intersection over Union (IoU)

IoU digunakan untuk mengukur tingkat tumpang tindih antara *bounding box* hasil prediksi model (B_p) dan *bounding box* sebenarnya berdasarkan anotasi (*ground truth*) (B_{gt}). Perhitungan IoU pada bagian ini merupakan contoh perhitungan untuk menunjukkan penerapan persamaan IoU.

Sebagai contoh, *ground truth* memiliki koordinat sudut kiri atas (100,100) dan sudut kanan bawah (200,200) sedangkan *bounding box* hasil prediksi memiliki koordinat sudut kiri atas (120, 120) dan sudut kanan bawah (220,220).

Luas masing-masing *bounding box* dihitung berdasarkan selisih koordinat horizontal dan vertikal. Luas *ground truth* adalah:

$$\left|B_{gt}\right| = (200 - 100) \times (200 - 100) = 100 \times 100 = 10.000 \text{ piksel}^2$$

Sedangkan luas *bounding box* hasil prediksi adalah:

$$\left|B_{p}\right| = (220 - 120) \times (220 - 120) = 100 \times 100 = 10.000 \text{ piksel}^2$$

Selanjutnya, daerah yang saling bertumpuk (*intersection*) berada pada koordinat (120,120) sampai (200,200). Dengan demikian, lebar dan tinggi daerah *intersection* masing-masing adalah 80 piksel, sehingga:

$$\left|B_p \cap B_{gt}\right| = 80 \times 80 = 6.400 \text{ piksel}^2$$

Setelah luas *intersection* diperoleh, luas gabungan (*union*) kedua *bounding box* dihitung dengan mengurangi luas *intersection* dari jumlah luas kedua *bounding box*. Persamaannya adalah:

$$\left|B_p \cup B_{gt}\right| = \left|B_p\right| + \left|B_{gt}\right| - \left|B_p \cap B_{gt}\right|$$

Dengan memasukkan nilai yang telah diperoleh:

$$\left|B_p \cup B_{gt}\right| = 10.000 + 10.000 - 6.400 = 13.600 \text{ piksel}^2$$

Dengan memasukkan nilai *intersection* dan *union*:

$$IoU\left(B_p, B_{gt}\right) = \frac{6.400}{13.600} = 0{,}471$$

Dengan demikian, nilai IoU yang diperoleh adalah 0,471 atau sekitar 47,1%. Nilai tersebut menunjukkan tingkat kesesuaian posisi *bounding box* prediksi terhadap *ground truth* berdasarkan luas daerah yang beririsan dibandingkan dengan luas gabungannya. Semakin besar nilai IoU, semakin besar pula tingkat tumpang tindih antara *bounding box* prediksi dan *ground truth*. Nilai IoU selanjutnya digunakan dalam menentukan kecocokan antara hasil prediksi dan *ground truth*, serta menjadi salah satu dasar dalam proses *Non-Maximum Suppression* (NMS).

Kemudian setelah menemukan hasil dari IoU, maka selanjutnya menghitung CIoU dengan rumus:

$$CIoU = IoU - \frac{\rho^2(b, b_{gt})}{c^2} - \alpha v$$

Sehingga mendapatkan pusat Ground truth:

$$C_{gt} = \left(\frac{100 + 200}{2}, \frac{100 + 200}{2}\right) = (150,150)$$

Kemudian pusat prediksinya:

$$C_p = \left(\frac{120 + 220}{2}, \frac{120 + 220}{2}\right) = (170,170)$$

Kemudian hitung jarak kuadrat antara kedua pusat

$$\begin{aligned} \rho^2 &= (170 - 150)^2 + (170 - 150)^2 \\ &= 20^2 + 20^2 \\ &= 400 + 400 \\ &= 800 \end{aligned}$$

Diagonal *bounding box* yang mencakup kedua kotak adalah:

$$\begin{aligned} c^2 &= (220 - 100)^2 + (220 - 100)^2 \\ &= 120^2 + 120^2 \\ &= 14.400 + 14.400 \\ &= 28.800 \end{aligned}$$

Maka menjadi:

$$c_2\rho_2 = \frac{28.800}{800} = 0{,}027778$$

Karena menggunakan $v = 0$, maka:

$$CIoU = 0{,}470588 - 0{,}027778 - 0 = 0{,}442810$$

Setelah menemukan nilai CIoU, kemudian mencari nilai CIoU Loss menggunakan rumus:

$$L_{CIoU} = 1 - CIoU$$

Maka menghasilkan:

$$L_{CIoU} = 1 - 0{,}442810 = 0{,}557190$$

Maka didapatkan hasil L_{CIoU} yaitu 0.557190.

3.5.2.4 UBinary Cross-Entropy Loss

Classification loss pada penelitian ini dihitung menggunakan *Binary Cross-Entropy* (BCE). Perhitungan berikut merupakan contoh penerapan persamaan BCE. Misalkan target kelas dan probabilitas prediksi model, maka nilai *classification loss* dihitung sebagai berikut:

$$L_{\text{BCE}} = -[1 \log(0{,}80) + (1 - 1) \log(1 - 0{,}80)]$$

Kemudian:

$$L_{\text{BCE}} = -[1 \log(0{,}80) + 0 \log(0{,}20)] \approx 0{,}223$$

Dengan demikian, nilai *classification loss* yang diperoleh adalah 0,223. Nilai tersebut menunjukkan besarnya kesalahan prediksi pada contoh yang digunakan. Semakin mendekati probabilitas prediksi terhadap target kelas yang sebenarnya, semakin kecil nilai *classification loss* yang dihasilkan

3.5.2.5 Total Loss

Total loss merupakan gabungan dari box loss, classification loss, dan Distribution Focal Loss. Dengan bobot (*gain*) yang digunakan sebagai acuan pada konfigurasi Ultralytics, yaitu box = 7,5, cls = 0,5, dan dfl = 1,5, maka:

$$L_{total} = 7{,}5L_{CIoU} + 0{,}5L_{BCE} + 1{,}5L_{DFL}$$

Dari hasil yang sudah di hitung, maka L_{CIoU}: 0,557190, L_{BCE} : 0,223, dan L_{DFL} :0,10, maka:

$$L_{\text{total}} = (7{,}5 \times 0{,}557190) + (0{,}5 \times 0{,}223) + (1{,}5 \times 0{,}10)$$

Maka akan dihasilkan menjadi:

$$7{,}5 \times 0{,}557190 = 4{,}178925$$

$$0{,}5 \times 0{,}223 = 0{,}1115$$

$$1{,}5 \times 0{,}10 = 0{,}15$$

Sehingga menjadi:

$$L_{\text{total}} = 4{,}178925 + 0{,}1115 + 0{,}15 = 4{,}440425$$

Maka total loss ditemukan menjadi 4,440425 kemudian dibulatkan menjadi 4,44 %.

3.5.2.6 Pembaruan bobot melalui backpropagation

Setelah nilai *loss* diperoleh, proses selanjutnya adalah melakukan pembaruan bobot melalui *backpropagation*. Pembaruan bobot dilakukan menggunakan metode *gradient descent*. Secara umum, persamaan pembaruan bobot dapat dituliskan sebagai berikut:

$$w_{baru} = w_{lama} - \eta \left(\frac{\partial L}{\partial w}\right)$$

Berdasarkan perhitungan sebelumnya, diperoleh nilai (IoU=0,470588). Dengan mempertimbangkan jarak pusat kedua *bounding box* dan kesamaan aspek rasio, diperoleh nilai (CIoU=0,442810), sehingga nilai (CIoU\ loss) adalah:

$$L_{CIoU} = 1 - CIoU$$

$$L_{CIoU} = 1 - 0{,}442810 = 0{,}557190$$

Nilai tersebut selanjutnya digunakan sebagai nilai pada proses pembaruan bobot. Dengan bobot awal ($w_{lama} = 0{,}50$), *learning rate* ($\eta = 0{,}01$) dan nilai gradien yang digunakan sebesar (0,557190), maka:

$$w_{baru} = 0{,}50 - (0{,}01 \times 0{,}557190)$$

$$w_{baru} = 0{,}50 - 0{,}00557190$$

$$w_{baru} = 0{,}49442810$$

Maka dari perhitungan tersebut dapat dihasilkan nilai 0,49442810.

3.5.2.7 Penentuan Sampel Positif dengan Task-Aligned Assigner

Pada proses pelatihan, tidak seluruh kandidat prediksi ditetapkan sebagai sampel positif. Model perlu menentukan kandidat yang paling sesuai dengan *ground truth*. Pada YOLOv8, proses tersebut dilakukan menggunakan *Task-Aligned Assigner* (TAL).

TAL mempertimbangkan kualitas klasifikasi dan kualitas lokasi. Metrik *alignment* dinyatakan berdasarkan skor kelas dan nilai IoU. Persamaan metrik *alignment* dinyatakan sebagai:

$$A = s^{\alpha} \times u^{\beta}$$

dengan (s) merupakan skor kelas, (u) merupakan nilai IoU antara *bounding box* prediksi dan *ground truth*, sedangkan (α) dan (β) merupakan parameter pengatur pengaruh skor kelas dan IoU terhadap nilai *alignment*.

Berdasarkan perhitungan *bounding box* sebelumnya, diperoleh nilai IoU:

$$IoU = \frac{6.400}{13.600} = 0{,}470588$$

Dengan menggunakan skor kelas$(s = 0{,}800)$,$(\alpha = 0{,}5)$, dan$(\beta = 6)$, maka nilai *alignment* dihitung sebagai berikut:

$$A = (0{,}800)^{0{,}5} \times (0{,}470588)^{6}$$

$$A = 0{,}894427 \times 0{,}010861$$

$$A \approx 0{,}009714$$

Dengan demikian, nilai *alignment* yang diperoleh adalah sekitar 0,0097. Nilai tersebut digunakan oleh TAL untuk membantu menentukan peringkat kandidat sampel positif berdasarkan kombinasi antara kualitas klasifikasi dan tingkat kesesuaian lokasi objek terhadap *ground truth*.

3.5.2.8 Proses Inferensi pada Satu Citra

Setelah proses pelatihan selesai, model YOLOv8 digunakan untuk melakukan inferensi terhadap citra baru. Pada tahap ini, citra masukan diproses oleh *backbone*

dan *neck* untuk menghasilkan *feature map* pada beberapa tingkat resolusi. Selanjutnya, *feature map* diteruskan ke *detection head* untuk menghasilkan prediksi kelas dan koordinat *bounding box*. Pada penelitian ini, citra masukan berukuran piksel dan *detection head* mengevaluasi 8.400 titik kandidat dari tiga tingkat *feature map.*

Pada setiap titik kandidat, model menghasilkan nilai *logit* untuk kelas objek. Nilai *logit* tersebut kemudian ditransformasikan menjadi probabilitas menggunakan fungsi sigmoid. Fungsi sigmoid dinyatakan sebagai:

$$p = \frac{1}{1 + e^{-z}}$$

dengan merupakan nilai *logit* yang dihasilkan oleh jaringan dan merupakan probabilitas hasil transformasi. Nilai probabilitas tersebut menjadi dasar dalam penentuan skor *confidence* pada proses inferensi.

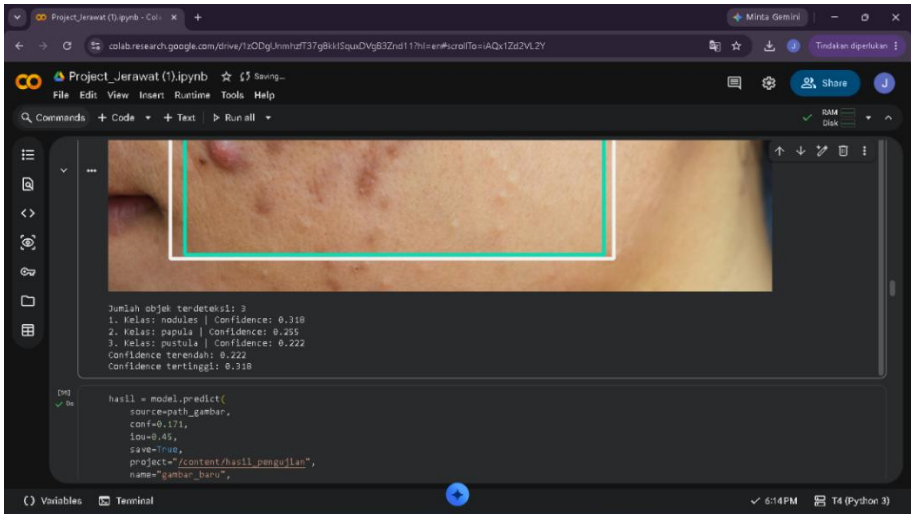
$$p = \frac{1}{1 + e^{-(-0{,}763)}}$$

$$p = 1/\left(1 + e^{(0{,}763)}\right)$$

$$p \approx 0{,}318$$

Pada hasil inferensi yang digunakan dalam penelitian ini, model memberikan nilai *confidence* untuk tiga objek yang terdeteksi, yaitu Nodules sebesar 0,318. Dengan cara yang sama nilai logit Papula sebesar 0,255, dan Pustula sebesar 0,222.

Untuk memperlihatkan keluaran nyata dari proses inferensi, digunakan satu citra wajah sebagai contoh. Setelah citra diproses oleh model, diperoleh tiga hasil deteksi.



Berdasarkan keluaran program pada citra tersebut, diperoleh:

NO	Kelas	Confidence
1.	Nodules	0.318
2.	Papula	0,255
3.	Pustula	0,22

Hasil tersebut kemudian diperiksa terhadap *confidence threshold* sebesar 0,171.

Untuk Nodules: 0,318 > 0.171, Sehingga prediksi dipertahankan.

Untuk Papula: 0,255 > 0,171, sehingga prediksi dipertahankan.

Untuk pustula: 0,222 > 0,171, Sehingga prediksi dipertahankan.

Dengan demikian, ketiga prediksi memenuhi batas *confidence threshold* yang digunakan

3.5.2.9 Perhitungan dari Keluaran Inferensi

Setelah model memberikan keluaran, dapat dilakukan perhitungan tambahan untuk menganalisis hasil prediksi.

Rata-rata *confidence* dihitung dengan:

$$\bar{C} = \frac{0{,}318 + 0{,}255 + 0{,}222}{3} = \frac{0{,}795}{3} = 0{,}265$$

Selanjutnya, nilai *confidence* tertinggi adalah:

$$C_{\max} = \max(0{,}318; 0{,}255; 0{,}222) = 0{,}318$$

sedangkan nilai terendah:

$$C_{\min} = \min\{0{,}318;\ 0{,}255;\ 0{,}222\}$$

Selisih kedua nilai tersebut:

$$\Delta C = 0{,}318 - 0{,}222$$

Berdasarkan hasil tersebut, prediksi dengan nilai *confidence* tertinggi pada citra contoh adalah Nodules sebesar 0,318, maka dapat disimpulkan bahwa gambar menunjukan kelas nodules.

3.6Evaluation

Tahap evaluation dilakukan terhadap setiap hasil eksperimen menggunakan data validation dan testing yang tidak digunakan untuk memperbarui hasil model. Tujuannya adalah membandingkan performa konfigurasi, menentukan model terbaik, dan mengidentifikasi kesalahan deteksi. Evaluasi menggunakan precision, recall, mAP@0.5, mAP@0.5:0.95, confusion matrix, serta kurva F1-Confidence.

3.6.1 Precision

Mengukur proporsi prediksi jerawat yang benar dari seluruh objek yang diprediksi sebagai jerawat. Nilai precision tinggi menunjukkan jumlah false positive yang rendah.

Precision dihitung menggunakan persamaan:

$$\text{Precision} = \frac{TP}{TP + FP}$$

TP = 40 dan FP = 10, maka Precision = 40 / (40 + 10) = 0,80 atau 80%. Artinya, 80% objek yang diprediksi sebagai jerawat merupakan prediksi yang benar.

3.6.2 Recall

Mengukur kemampuan model menemukan seluruh objek jerawat yang terdapat pada anotasi. Nilai recall tinggi menunjukkan jumlah false negative yang rendah.

Recall dihitung menggunakan persamaan:

$$\text{Recall} = \frac{TP}{TP + FN}$$

TP = 40 dan FN = 20, maka Recall = 40 / (40 + 20) = 0,667 atau sekitar 66,7%. Artinya, model berhasil menemukan sekitar 66,7% objek jerawat yang terdapat pada anotasi.

3.6.3 Mean Average Precision (mAP)

mAP@0.5 mengukur rata-rata Average Precision pada IoU 0,50, sedangkan mAP@0.5:0.95 menggunakan rentang IoU yang lebih ketat. Metrik utama pemilihan model adalah mAP@0.5:0.95 karena menilai ketepatan kelas sekaligus lokasi bounding box.

3.6.3.1 F1-Score

F1-score digunakan untuk melihat keseimbangan antara precision dan recall. Rumusnya adalah:

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Precision = 0,80 dan Recall = 0,667, maka F1 = 2 × (0,80 × 0,667) / (0,80 + 0,667) ≈ 0,727. Nilai F1 yang semakin mendekati 1 menunjukkan keseimbangan precision dan recall yang semakin baik.

mAP@0.5 mengukur rata-rata Average Precision pada IoU 0,50, sedangkan mAP@0.5:0.95 menggunakan rentang IoU yang lebih ketat. Metrik utama pemilihan model adalah mAP@0.5:0.95 karena menilai ketepatan kelas sekaligus lokasi bounding box.

Average Precision (AP) merupakan luas di bawah kurva Precision-Recall untuk satu kelas, sedangkan mAP merupakan rata-rata AP seluruh kelas. Pada penelitian ini terdapat lima kelas, sehingga secara sederhana:

$$\text{mAP} = \frac{AP_{\text{Blackhead}} + AP_{\text{Nodul}} + AP_{\text{Papula}} + AP_{\text{Pustula}} + AP_{\text{Whitehead}}}{5}$$

Pada model terbaik, nilai AP yang tercatat adalah 0,509 untuk Blackhead, 0,371 untuk Nodul, 0,481 untuk Papula, 0,701 untuk Pustula, dan 0,364 untuk Whitehead. Dengan demikian:

$$\text{mAP@0.5} = \frac{0{,}509 + 0{,}371 + 0{,}481 + 0{,}701 + 0{,}364}{5} = 0{,}4852 \approx 0{,}485$$

Hasil tersebut sesuai dengan nilai mAP@0.5 sebesar 0,485 pada model terbaik. Sementara itu, mAP@0.5:0.95 menghitung AP pada sepuluh threshold IoU, yaitu 0,50; 0,55; 0,60; 0,65; 0,70; 0,75; 0,80; 0,85; 0,90; dan 0,95, kemudian dirata-ratakan terhadap seluruh kelas.

3.6.4 Confusion Matrix dan F1-Confidence

Confusion matrix digunakan untuk melihat kelas yang terdeteksi benar, kelas yang tertukar, false positive, dan false negative. Kurva F1-Confidence digunakan untuk menentukan threshold confidence yang memberikan keseimbangan terbaik antara precision dan recall.

Hasil keenam eksperimen dicatat menggunakan format metrik yang sama. Konfigurasi dengan mAP@0.5:0.95 tertinggi dipilih sebagai kandidat utama,

kemudian diperiksa kembali melalui confusion matrix, validation loss, dan pengujian citra baru. Apabila performa training meningkat tetapi validation loss memburuk, model dinilai mengalami overfitting dan konfigurasi sebelumnya dipertimbangkan.

3.7Deployment

Tahap deployment menerapkan bobot best.pt ke dalam dashboard berbasis Streamlit. Tujuan tahap ini adalah menyediakan antarmuka yang memungkinkan pengguna mencoba model melalui unggahan gambar, video, dan kamera real-time tanpa menjalankan kode Google Colaboratory secara langsung.

Proses deployment dimulai dengan menempatkan best.pt pada direktori models di proyek Streamlit. Aplikasi memuat model melalui Ultralytics, menerima masukan pengguna, menjalankan inferensi menggunakan threshold confidence, kemudian menggambar bounding box, label kelas, dan confidence pada citra hasil.

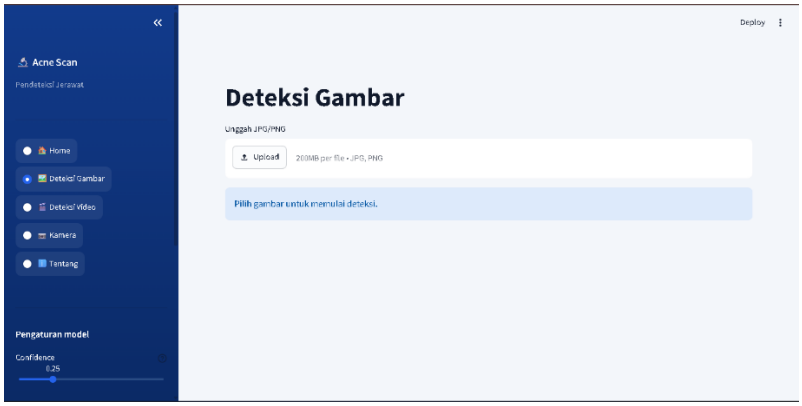
Web dijalankan secara lokal melalui perintah streamlit run app.py dan dapat diakses pada localhost. Struktur aplikasi terdiri dari halaman utama, deteksi gambar, deteksi video, kamera real-time, dan informasi sistem. Tampilan dashboard ditunjukkan pada Gambar 3.8.



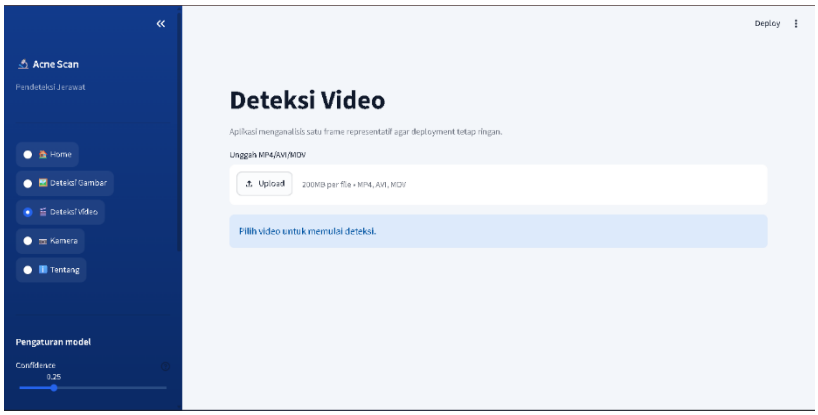
Gambar 3. 8 Tampilan Dashboard

Pada halaman deteksi, pengguna dapat memilih berkas melalui tombol Browse File atau menggunakan drag-and-drop. Citra asli dan hasil deteksi

ditampilkan berdampingan agar lokasi bounding box dan kelas prediksi dapat dibandingkan. Tampilan unggah gambar dan video ditunjukkan pada

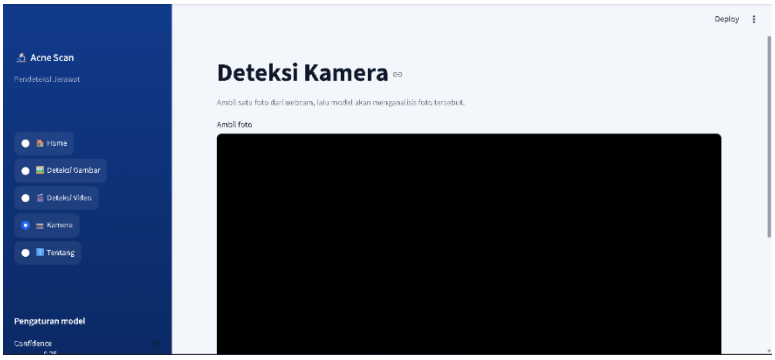


Gambar 3. 9 Tampilan Unggah foto



Gambar 3. 10 Tampilan Unggah Video

Selanjutnya, gambar atau video yang telah diunggah oleh pengguna akan diproses dan dianalisis oleh sistem. Hasil analisis tersebut kemudian ditampilkan di samping file yang telah diunggah sehingga pengguna dapat melihat perbandingan secara lebih jelas dan informatif. Selain menampilkan hasil analisis, sistem juga memberikan informasi mengenai penyebab munculnya jerawat beserta solusi dan langkah penanganan yang dapat dilakukan. Dengan demikian, pengguna tidak hanya memperoleh hasil deteksi, tetapi juga mendapatkan edukasi serta rekomendasi penanganan untuk membantu mengatasi permasalahan jerawat yang dialami.



Gambar 3. 11 Fitur kamera visual secara *real-time*

Selain fitur unggah gambar dan video, pada website ini juga tersedia fitur kamera visual secara *real-time* yang memungkinkan pengguna melakukan deteksi jerawat secara langsung tanpa perlu mengunggah foto maupun video terlebih dahulu. Melalui fitur ini, sistem akan secara otomatis menganalisis jenis jerawat yang terdeteksi melalui kamera, kemudian menampilkan hasil analisis beserta informasi mengenai penyebab dan solusi penanganannya. Dengan adanya fitur *real-time detection* ini, pengguna dapat memperoleh hasil analisis dengan lebih cepat, praktis, dan interaktif.

BAB IV
HASIL DAN PEMBAHASAN

4.1 Hasil Penelitian

Penelitian ini menghasilkan model deteksi objek untuk mengidentifikasi jenis jerawat pada citra digital menggunakan arsitektur YOLOv8. Tahapan eksperimen meliputi pengambilan dataset melalui Roboflow, konfigurasi dataset berformat YOLOv8, pelatihan model, validasi kinerja, pengujian pada citra baru, serta penyimpanan bobot model terbaik. Penyajian hasil pada bab ini mengikuti urutan proses eksperimen agar hubungan antara konfigurasi pelatihan, hasil evaluasi, dan implementasi model dapat dijelaskan secara sistematis.

4.1.1 Hasil Akuisisi dan Persiapan dataset

Dataset penelitian diperoleh dari proyek Roboflow deteksi jerawat dan diunduh dalam format YOLOv8. Proses pengunduhan menghasilkan direktori dataset beserta berkas data.yaml. Berkas tersebut berfungsi sebagai konfigurasi yang memuat lokasi data latih, validasi, pengujian, jumlah kelas, serta nama kelas. Pemanfaatan format YOLOv8 memastikan bahwa citra dan anotasi bounding box dapat dibaca secara langsung oleh pustaka Ultralytics.

Berdasarkan kelas yang tersimpan pada model hasil pelatihan, objek yang dideteksi terdiri atas lima kelas, yaitu Jerawat Blackheads, nodules, papula, pustula, dan whitehead. Penamaan kelas pada sistem dapat diseragamkan menjadi Blackhead, Nodules, Papula, Pustula, dan Whitehead agar lebih konsisten saat ditampilkan pada antarmuka aplikasi.

Tabel 4. 1 Distribusi Dataset Berdasarkan Kelas

No.	Kelas	Training	Validation	Testing
1	Blackhead	57	12	7

No.	Kelas	Training	Validation	Testing
2	Whitehead	83	18	12
3	Papula	134	39	20
4	Pustula	85	27	11
5	Nodul	110	27	23

4.1.2 Hasil Konfigurasi Pelatihan Model

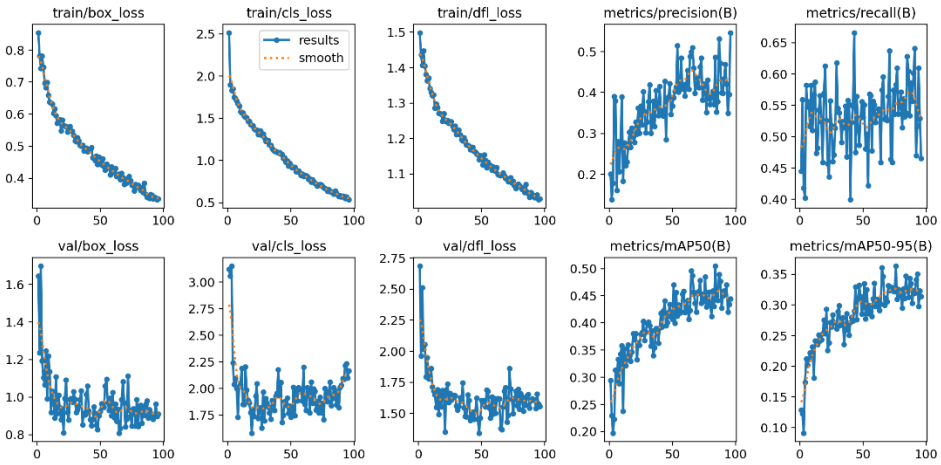
Pelatihan dilakukan pada lingkungan Google Colab menggunakan pustaka Ultralytics dan Roboflow. Model awal yang digunakan adalah YOLOv8s dengan bobot pralatih yolov8s.pt. Pemilihan varian small memberikan kompromi antara kemampuan ekstraksi fitur, kebutuhan komputasi, dan kecepatan inferensi. Bobot pralatih kemudian disesuaikan melalui proses transfer learning menggunakan dataset penelitian.

Tabel 4. 2 Konfigurasi Pelatihan Model YOLOv8

No.	Parameter	Nilai	Keterangan
1	Arsitektur	YOLOv8s	Varian small
2	Bobot awal	yolov8s.pt	Bobot pralatih
3	Epoch maksimum	80, 100, dan 120	Variasi maksimum epoch
4	Image size	640 × 640	Ukuran citra masukan
5	Batch size	16	Jumlah citra setiap batch

No.	Parameter	Nilai	Keterangan
6	Patience	20	Parameter early stopping
7	Format dataset	YOLOv8	Hasil ekspor Roboflow
8	Nama eksperimen	12 pengujian terencana	12 selesai
9	Rasio data	80:15:5; 50:20:30; 60:20:20; 70:20:10.	Empat variasi rasio;

Pelatihan dilakukan pada empat konfigurasi rasio data dengan maksimum 80, 100, dan 120 epoch serta patience 20.



Gambar 4. 1 Grafik Hasil Pelatihan Model YOLOv8

Gambar 4.1 menunjukkan bahwa train/box_loss, train/cls_loss, dan train/dfl_loss menurun secara konsisten selama pelatihan. Validation loss menurun tajam pada epoch awal, kemudian berfluktuasi dan cenderung stabil. Pada saat yang

sama, precision, recall, mAP@0.5, dan mAP@0.5:0.95 mengalami peningkatan. Pola tersebut menunjukkan bahwa model berhasil mempelajari karakteristik objek, meskipun fluktuasi metrik validasi menunjukkan masih terdapat variasi performa antar epoch.

4.1.3 Hasil Eksperimen Variasi Konfigurasi

Eksperimen membandingkan rasio 80:15:5, 50:20:30, 60:20:20, dan 70:20:10 pada maksimum 80, 100, dan 120 epoch. Hasil agregat precision, recall, mAP@0.5, dan mAP@0.5:0.95 disajikan pada Tabel 4. 3

Tabel 4. 3 Perbandingan Hasil Eksperimen

Uji	Rasio Data	Epoch	Precision	Recall	mAP@0.5	mAP@0.5: 0.95
1	80:15:5	80	0,501	0,509	0,459	0,329
2	80:15:5	100	0,510	0,505	0,463	0,323
3	80:15:5	120	0,414	0,533	0,485	0,363
4	50:20:30	80	0,305	0,527	0,400	0,301
5	50:20:30	100	0,326	0,565	0,389	0,316
6	50:20:30	120	0,391	0,457	0,400	0,308
7	60:20:20	80	0,372	0,633	0,422	0,303
8	60:20:20	100	0,359	0,577	0,411	0,308
9	60:20:20	120	0,466	0,462	0,398	0,299
10	70:20:10	80	0,459	0,590	0,472	0,354
11	70:20:10	100	0,431	0,554	0,438	0,322
12	70:20:10	120	0,457	0,483	0,438	0,342

Berdasarkan 12 hasil yang tersedia, konfigurasi rasio 80:15:5 dengan maksimum 120 epoch memperoleh mAP@0.5:0.95 tertinggi sebesar 0,363 sehingga menjadi model terbaik sementara secara keseluruhan. Model terbaik pada rasio 50:20:30 adalah maksimum 100 epoch dengan mAP@0.5:0.95 sebesar 0,316. Pada rasio 60:20:20, hasil terbaik juga diperoleh maksimum 100 epoch sebesar 0,308. Pada rasio 70:20:10, hasil terbaik sementara diperoleh maksimum 80 epoch sebesar 0,354.

4.1.4 Hasil Evaluasi Model

Model terbaik dievaluasi menggunakan metode val() pada Ultralytics. Evaluasi menghasilkan nilai rata-rata precision, recall, mean Average Precision pada ambang Intersection over Union 0,50 (mAP50), dan mean Average Precision pada rentang IoU 0,50 sampai 0,95 (mAP50-95). Keempat metrik tersebut digunakan karena penelitian berfokus pada deteksi objek, sehingga penilaian tidak hanya memperhatikan ketepatan kelas, tetapi juga kesesuaian lokasi bounding box.

Tabel 4. 4 Hasil Evaluasi Model Terbaik

No.	Metrik	Nilai	Keterangan
1	Precision	0,414	Ketepatan prediksi positif
2	Recall	0,533	Kemampuan menemukan objek
3	mAP@0.5	0,485	AP rata-rata pada IoU 0,50
4	mAP@0.5:0.95	0,363	AP rata-rata pada berbagai IoU

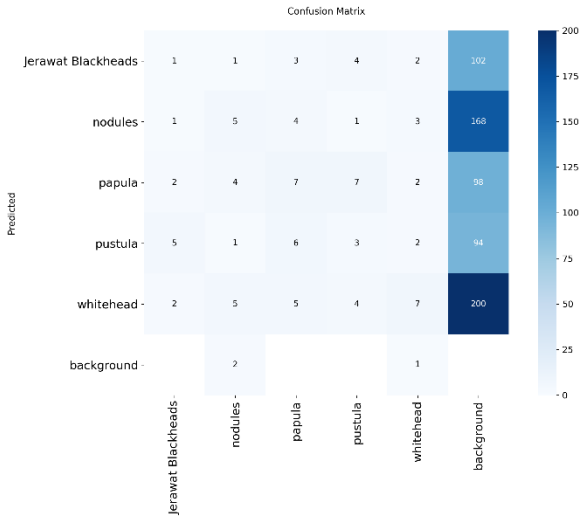
Tabel 4. 5 Hasil Evaluasi per Kelas pada Konfigurasi 120 Epoch

No.	Kelas	Precision	Recall	mAP@0.5	mAP@0.5:0.95
1	Jerawat Blackheads	0,329	0,727	0,509	0,427
2	Nodules	0,389	0,532	0,371	0,231
3	Papula	0,437	0,560	0,481	0,427
4	Pustula	0,659	0,684	0,701	0,583
5	Whitehead	0,258	0,412	0,364	0,146

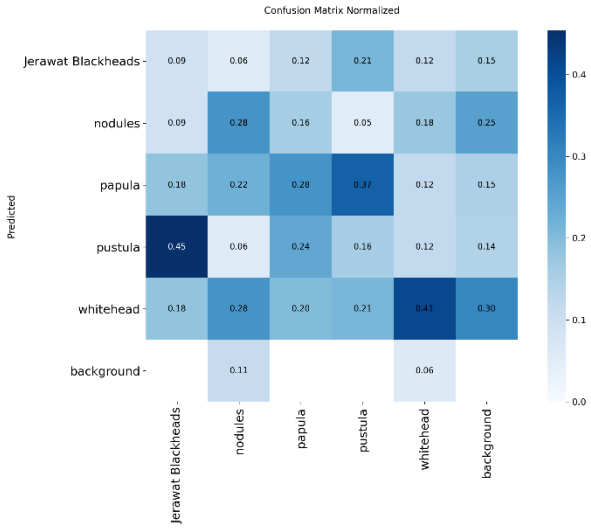
Model terbaik , yaitu rasio 80:15:5 dengan maksimum 120 epoch, memperoleh precision 0,414, recall 0,533, mAP@0.5 0,485, dan mAP@0.5:0.95 0,363. Pelatihan berhenti pada epoch ke-96 dan bobot best.pt berasal dari epoch ke-76. Hasil evaluasi agregat ditampilkan pada Tabel 4. 5 dan hasil per kelas pada Tabel 4. 5.

4.1.3.1 Confusion Matrix

Confusion matrix menunjukkan hubungan antara kelas aktual dan kelas hasil prediksi. Nilai pada diagonal utama menunjukkan prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi antarkelas. Baris atau kolom background memperlihatkan objek yang terlewat sebagai false negative dan deteksi yang tidak memiliki pasangan anotasi sebagai false positive.



Gambar 4. 2 Confusion Matrix Model YOLOv8



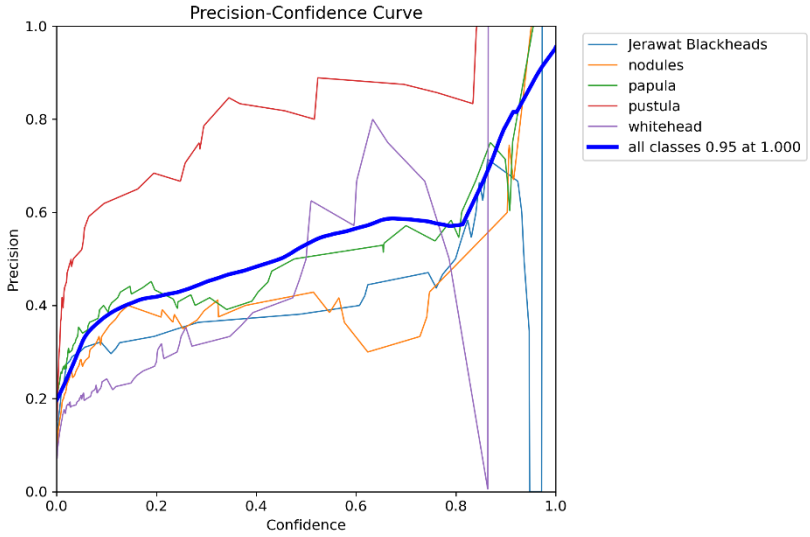
Gambar 4. 3 Confusion Matrix Ternormalisasi

Berdasarkan Gambar 4.2, dengan kelas aktual pada kolom dan kelas prediksi pada baris, jumlah prediksi benar tertinggi pada diagonal utama diperoleh kelas papula dan whitehead, masing-masing sebanyak 7 objek. Kesalahan antarkelas yang menonjol adalah objek pustula yang diprediksi sebagai papula sebanyak 7 objek serta objek papula yang diprediksi sebagai pustula sebanyak 6 objek. Kolom background juga menunjukkan false positive yang tinggi, terutama pada whitehead sebanyak 200 prediksi dan nodules sebanyak 168 prediksi. Pada Gambar 4.3, nilai diagonal ternormalisasi tertinggi diperoleh whitehead sebesar 0,41, diikuti nodules dan papula sebesar 0,28, pustula sebesar 0,16, serta Jerawat Blackheads sebesar

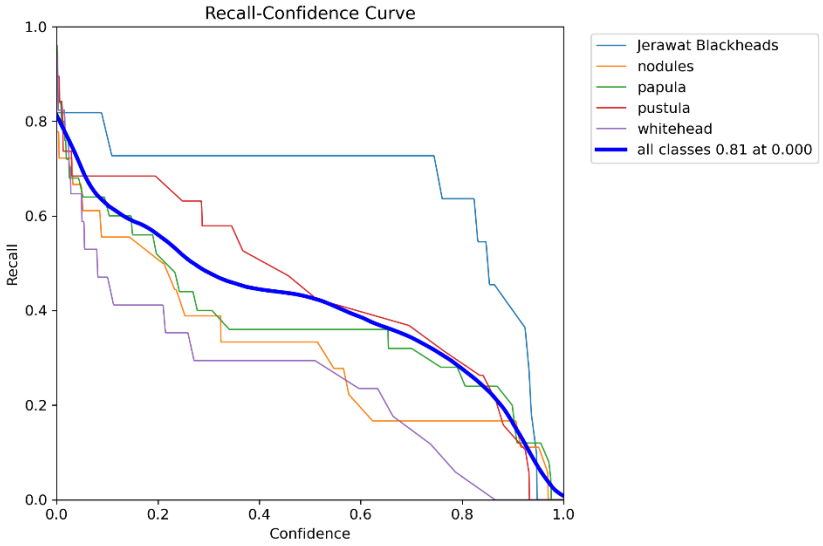
0,09. Hasil ini menunjukkan bahwa whitehead memiliki proporsi prediksi benar tertinggi, sedangkan Jerawat Blackheads masih paling sulit dikenali secara konsisten.

4.1.3.2 Kurva Precision, Recall, F1, dan PR

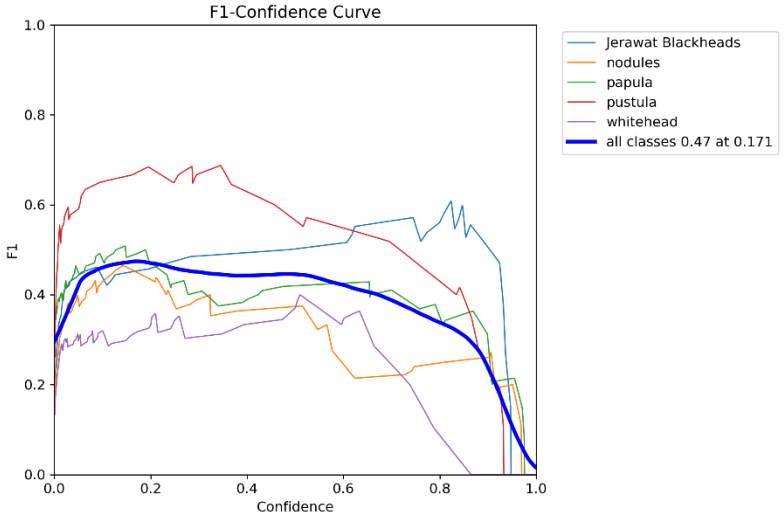
Kurva Precision-Confidence memperlihatkan perubahan precision ketika nilai confidence dinaikkan, sedangkan kurva Recall-Confidence menunjukkan perubahan kemampuan model menemukan objek. Kurva F1-Confidence dapat digunakan untuk memilih confidence yang memberikan keseimbangan terbaik antara precision dan recall. Adapun kurva Precision-Recall menggambarkan trade-off antara ketepatan prediksi dan kemampuan menemukan objek untuk masing-masing kelas.



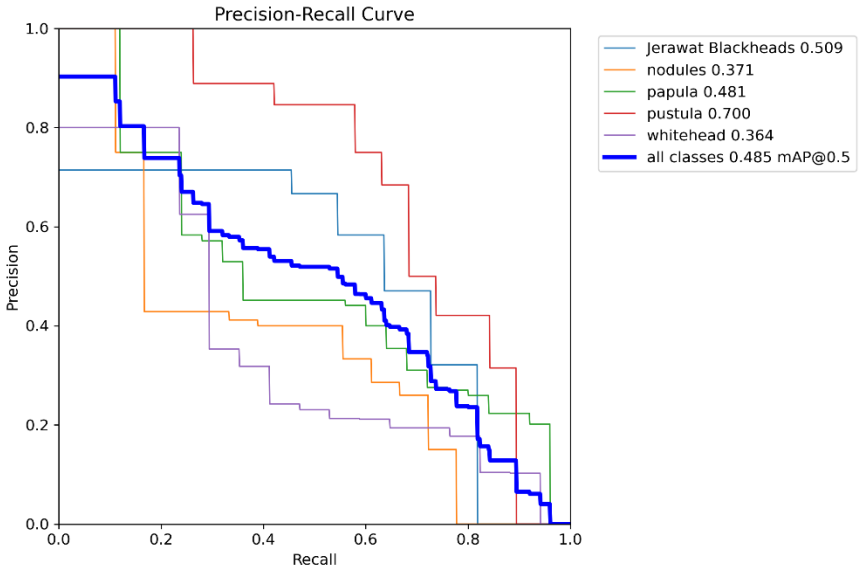
Gambar 4. 4 Kurva *Precision-Confidence*



Gambar 4. 5 Kurva Recall-Confidence



Gambar 4. 6 Kurva *F1-Confidence*

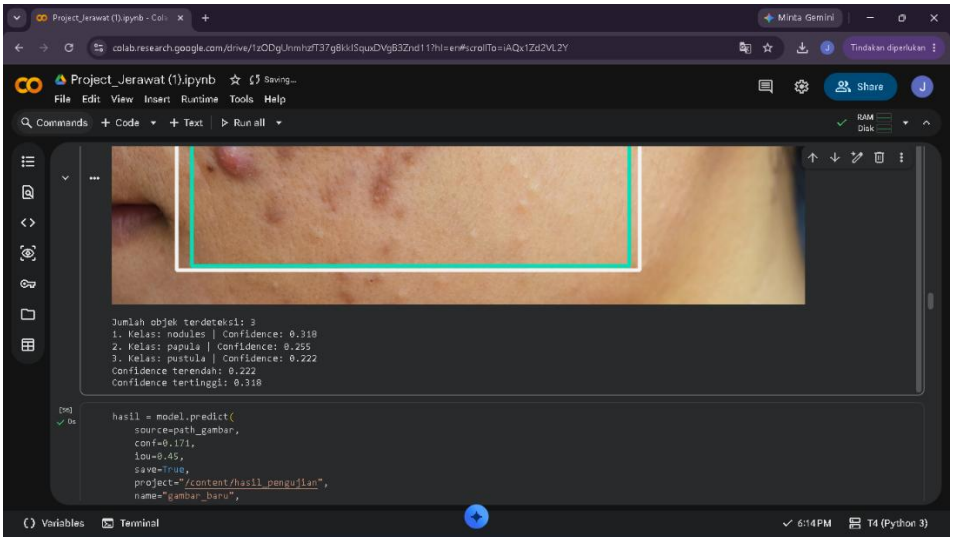


Gambar 4. 7 Kurva Precision-Recal

Kurva Precision-Confidence menunjukkan precision seluruh kelas mencapai 0,95 pada confidence 1,000, tetapi pada threshold yang sangat tinggi hanya sedikit prediksi yang dipertahankan sehingga recall menurun mendekati nol. Kurva Recall-Confidence menunjukkan recall seluruh kelas sebesar 0,81 pada confidence 0,000 dan terus menurun ketika threshold dinaikkan. Berdasarkan kurva F1-Confidence, performa paling seimbang diperoleh pada confidence 0,171 dengan F1-score 0,47. Oleh karena itu, nilai 0,171 dapat digunakan sebagai threshold awal deployment dan dibandingkan dengan confidence 0,15 yang digunakan pada pengujian Colab. Kurva Precision-Recall menghasilkan mAP@0.5 seluruh kelas sebesar 0,485. Average Precision tertinggi diperoleh kelas pustula sebesar 0,700, diikuti Jerawat Blackheads 0,509, papula 0,481, nodules 0,371, dan whitehead 0,364

4.1.5 Hasil Pengujian pada Citra Baru

Pengujian inferensi dilakukan dengan mengunggah satu citra baru ke Google Colab. Model best.pt kemudian menjalankan prediksi menggunakan confidence threshold 0,171, IoU threshold 0,45, dan ukuran input 640 piksel. Hasil inferensi ditampilkan dalam bentuk citra yang telah dilengkapi bounding box, nama kelas, serta nilai confidence.



Gambar 4. 8 Hasil Pengujian Model pada Citra Baru

Pada Gambar 4.8, model menghasilkan tiga bounding box yang masing-masing diprediksi sebagai nodules dengan confidence 0,318, papula dengan confidence 0,255, dan pustula dengan confidence 0,222. Dengan demikian, confidence keluaran berada pada rentang 0,222–0,318. Hasil tersebut menunjukkan keluaran inferensi model pada citra baru, sedangkan kesesuaian lokasi bounding box dan kelas prediksi tetap harus dibandingkan dengan anotasi kondisi sebenarnya.

4.1.6 Hasil Penyimpanan Model

Bobot terbaik hasil pelatihan disimpan dalam berkas best.pt. Berkas tersebut memuat arsitektur dan bobot model yang dapat dimuat kembali menggunakan kelas YOLO dari Ultralytics. Selain format .pt, eksperimen juga melakukan serialisasi objek model ke format yolov8_model.pkl menggunakan pickle. Kedua berkas kemudian diunduh dari Google Colab sebagai persiapan implementasi model pada aplikasi.

Untuk implementasi, best.pt merupakan format utama yang lebih sesuai dengan alur Ultralytics karena dapat dimuat menggunakan YOLO('models/best.pt'). Penggunaan berkas .pkl perlu memperhatikan kesesuaian versi Python, PyTorch, dan Ultralytics karena serialisasi objek lengkap dapat mengalami masalah kompatibilitas ketika dipindahkan ke lingkungan yang berbeda.

4.2 Pembahasan

4.2.1 Analisis Konfigurasi Pelatihan

Pemanfaatan YOLOv8s menunjukkan bahwa penelitian memilih model berukuran relatif ringan dibandingkan varian medium, large, atau extra-large. Konfigurasi citra 640 piksel merupakan ukuran umum pada pelatihan YOLO dan sesuai dengan parameter inferensi yang digunakan. Batch size 16 memungkinkan beberapa citra diproses pada setiap iterasi, sementara patience 20 membantu mencegah pelatihan berlanjut tanpa peningkatan pada data validasi.

Transfer learning dari yolov8s.pt mempercepat konvergensi karena model telah memiliki kemampuan ekstraksi fitur umum. Efektivitas konfigurasi dibandingkan melalui 12 pengujian yang direncanakan pada Bab III. Pemilihan model terbaik menggunakan mAP@0.5:0.95 sebagai indikator utama, kemudian mempertimbangkan precision, recall, kestabilan validation loss, dan kebutuhan inferensi.

4.2.2 Analisis Kinerja Model

Perbandingan nilai precision dan recall menunjukkan bahwa model lebih kuat pada penemuan objek. Nilai recall sebesar 0,533 lebih tinggi daripada precision sebesar 0,414. Artinya, model mampu menemukan lebih banyak objek target, tetapi masih memiliki kemungkinan menghasilkan false positive yang lebih besar. Temuan ini sejalan dengan banyaknya prediksi pada kolom background pada confusion matrix.

Selisih antara mAP@0.5 dan mAP@0.5:0.95 adalah 0,122, yang diperoleh dari 0,485 dikurangi 0,363. Penurunan performa pada rentang IoU yang lebih ketat menunjukkan bahwa model telah mampu menemukan objek, tetapi ketepatan posisi bounding box masih perlu ditingkatkan.

4.2.3 Analisis Kesalahan dan Generalisasi

Hasil pengujian pada citra baru perlu dianalisis tidak hanya dari jumlah objek yang terdeteksi, tetapi juga dari kesesuaian lokasi bounding box dan kelasnya. Model dapat memberikan hasil berbeda pada citra dengan pencahayaan, resolusi,

jarak pengambilan, latar, dan skala objek yang berbeda dari data pelatihan. Deteksi yang muncul pada area non-target termasuk false positive, sedangkan objek target yang tidak memperoleh bounding box termasuk false negative.

Penggunaan confidence yang terlalu rendah dapat meningkatkan jumlah deteksi, tetapi juga meningkatkan kemungkinan prediksi keliru. Sebaliknya, confidence yang terlalu tinggi dapat menghilangkan deteksi yang sebenarnya benar tetapi memiliki keyakinan sedang. Oleh karena itu, threshold aplikasi sebaiknya ditetapkan berdasarkan kurva F1-Confidence dan diuji menggunakan kumpulan data uji beranotasi, bukan hanya berdasarkan satu citra.

Pengujian tambahan dilakukan terhadap 20 citra baru menggunakan confidence threshold 0,171 dan IoU threshold 0,45. Model menghasilkan deteksi pada 17 citra (85%) dan tidak menghasilkan deteksi pada 3 citra (15%), dengan total 26 bounding box. Berdasarkan kelas prediksi model, bounding box tersebut terdiri atas 9 papula, 8 pustula, 6 nodules, 2 whitehead, dan 1 Jerawat Blackheads, dengan rentang confidence 0,185–0,702. Jumlah tersebut menunjukkan frekuensi keluaran model dan belum dapat dinyatakan sebagai jumlah prediksi benar, false positive, atau false negative sebelum dibandingkan dengan anotasi kondisi sebenarnya pada setiap citra.

Tabel 4. 6 ingkasan Hasil Pengujian pada 20 Citra Baru

No.	**Keterangan**	**Jumlah/Nilai**	**Persentase/Keterangan**
1	Jumlah citra pengujian	20	100% dari citra
2	Citra menghasilkan deteksi	17	85% dari citra
3	Citra tanpa deteksi	3	15% dari citra
4	Total bounding box	26	Seluruh keluaran

No.	Keterangan	Jumlah/Nilai	Persentase/Keterangan
5	Papula	9	34,62% dari bounding box
6	Pustula	8	30,77% dari bounding box
7	Nodules	6	23,08% dari bounding box
8	Whitehead	2	7,69% dari bounding box
9	Jerawat Blackheads	1	3,85% dari bounding box
10	Rentang confidence	0,185–0,702	Threshold 0,171

4.3Deployment

Model best.pt diimplementasikan pada aplikasi berbasis Streamlit agar pengguna dapat mengunggah citra dan melihat hasil deteksi melalui peramban. Alur implementasi dimulai ketika pengguna memilih citra, kemudian aplikasi mengubah citra ke format RGB dan mengirimkannya ke model YOLO. Model menghasilkan koordinat bounding box, kelas, dan confidence yang selanjutnya divisualisasikan pada citra hasil deteksi.

Implementasi antarmuka deployment terdiri atas halaman utama, deteksi gambar, deteksi video, dan deteksi kamera. Tampilan setiap halaman ditunjukkan pada Gambar 4.9 sampai dengan Gambar 4.12.



Gambar 4. 9 Tampilan Dashboard

Gambar 4.9 menunjukkan halaman dashboard yang menjadi halaman utama aplikasi Sistem Deteksi Jerawat. Halaman ini menampilkan informasi umum mengenai model dan petunjuk singkat penggunaan aplikasi. Pada bagian kiri terdapat sidebar yang digunakan untuk berpindah ke halaman Home, Deteksi Gambar, Deteksi Video, Kamera, dan Tentang.

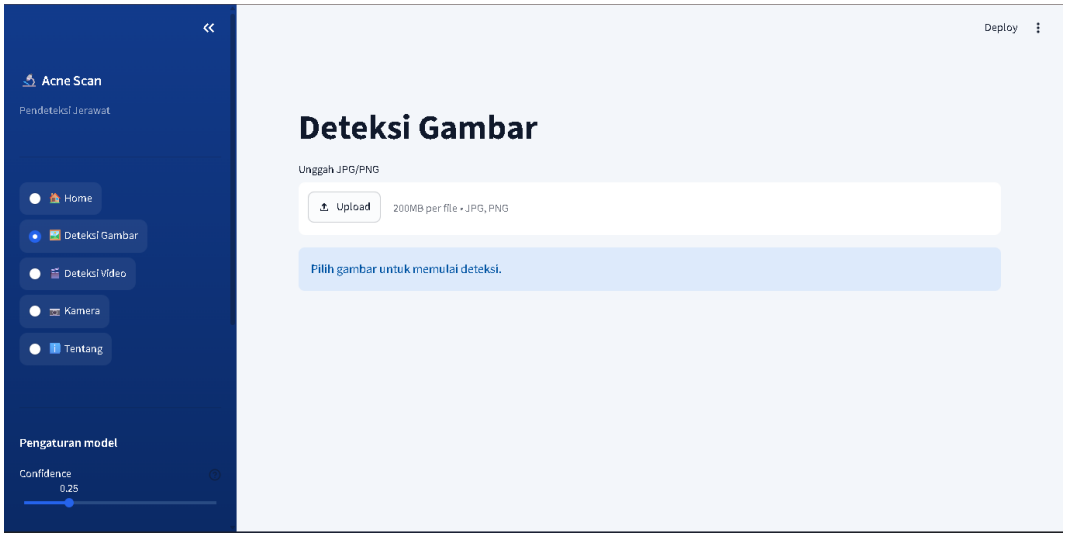
Dashboard menampilkan beberapa informasi konfigurasi, yaitu jumlah kelas model, nilai confidence awal, status model, dan mode aplikasi. Jumlah kelas model adalah lima kelas jerawat, yaitu Blackhead, Nodules, Papula, Pustula, dan Whitehead. Nilai confidence awal ditetapkan sebesar 0,25, yang berarti prediksi dengan confidence di bawah nilai tersebut tidak ditampilkan sebagai hasil deteksi.

Status model menunjukkan apakah berkas bobot best.pt berhasil dimuat oleh aplikasi. Pada gambar, status masih menunjukkan “Belum siap”, yang berarti model belum berhasil atau belum selesai dimuat pada saat tangkapan layar dilakukan. Sementara itu, keterangan “Lokal” menunjukkan bahwa aplikasi dijalankan melalui komputer lokal dan belum ditempatkan pada server publik.

Bagian “Cara Mencoba” berisi petunjuk penggunaan aplikasi. Pengguna diarahkan untuk membuka halaman Deteksi Gambar, mengunggah citra dengan pencahayaan yang jelas, kemudian melihat bounding box, nama kelas, dan nilai confidence yang

dihasilkan model. Pada bagian bawah terdapat peringatan bahwa hasil model merupakan keluaran penelitian atau edukasi dan bukan diagnosis medis.

Sidebar juga menyediakan pengaturan confidence melalui slider. Pengguna dapat menaikkan atau menurunkan threshold confidence sesuai kebutuhan. Nilai threshold yang rendah dapat menampilkan lebih banyak deteksi, tetapi berpotensi meningkatkan false positive. Sebaliknya, nilai threshold yang tinggi hanya menampilkan prediksi yang lebih meyakinkan, tetapi dapat menyebabkan beberapa objek tidak terdeteksi.



Gambar 4. 10 Tampilan Unggah foto

Gambar 4.10 menunjukkan halaman Deteksi Gambar yang digunakan untuk melakukan inferensi terhadap citra yang diunggah pengguna. Halaman ini menyediakan komponen file uploader yang menerima citra dengan format JPG atau PNG. Pengguna menekan tombol unggah, kemudian memilih citra jerawat yang tersimpan pada perangkat.

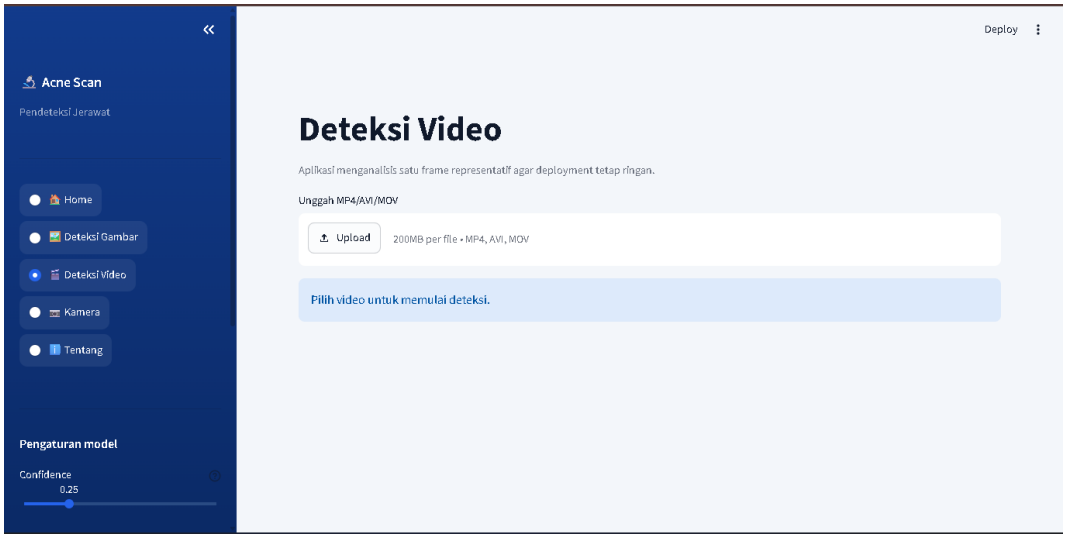
Sebelum citra diproses oleh model, aplikasi membaca berkas masukan dan mengubahnya ke format RGB. Citra kemudian dikirimkan ke model YOLOv8 dengan nilai confidence sesuai pengaturan pada sidebar. Model melakukan

ekstraksi fitur dan menghasilkan kandidat bounding box serta skor untuk setiap kelas jerawat.

Prediksi dengan confidence di bawah threshold akan dibuang, sedangkan kotak yang mendeteksi objek sama akan diseleksi menggunakan Non-Maximum Suppression. Setelah proses inferensi selesai, aplikasi menampilkan kembali citra yang telah dilengkapi bounding box, nama kelas jerawat, dan nilai confidence.

Halaman ini juga dapat menampilkan jumlah objek yang terdeteksi dan ringkasan kelas hasil prediksi. Apabila tidak terdapat prediksi yang memenuhi threshold, aplikasi menampilkan informasi bahwa tidak ada objek yang terdeteksi. Hasil nol deteksi tidak selalu berarti citra tidak memiliki jerawat karena kondisi tersebut dapat dipengaruhi oleh confidence threshold, pencahayaan, resolusi, sudut pengambilan citra, serta kemampuan generalisasi model.

Pada Gambar 4.10, pengguna belum memilih citra sehingga aplikasi masih menampilkan pesan “Pilih gambar untuk memulai deteksi”. Dengan demikian, gambar tersebut menunjukkan kondisi awal halaman sebelum proses inferensi dijalankan.



Gambar 4. 11 Tampilan Unggah Video

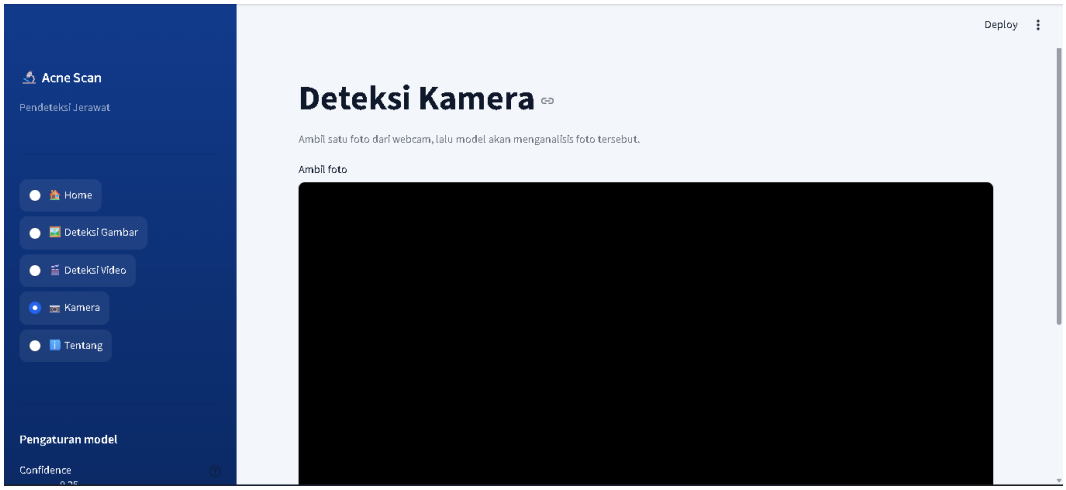
Gambar 4.11 menunjukkan halaman Deteksi Video yang digunakan untuk menerima masukan dalam format MP4, AVI, atau MOV. Pengguna dapat memilih berkas video dari perangkat melalui komponen file uploader yang tersedia.

Pada implementasi penelitian ini, aplikasi belum melakukan deteksi pada seluruh frame video secara terus-menerus. Aplikasi mengambil satu frame representatif dari video untuk dianalisis oleh model. Pendekatan tersebut digunakan agar kebutuhan komputasi dan waktu pemrosesan tetap ringan ketika aplikasi dijalankan secara lokal.

Frame yang dipilih diubah ke format citra RGB, kemudian dikirimkan ke model YOLOv8. Model melakukan inferensi dengan prosedur yang sama seperti pada deteksi gambar, yaitu menghasilkan bounding box, kelas prediksi, dan confidence. Hasil analisis selanjutnya ditampilkan dalam bentuk frame yang telah diberi bounding box dan label kelas.

Karena hanya menggunakan satu frame representatif, hasil pada halaman ini belum menggambarkan seluruh objek yang muncul sepanjang video. Objek jerawat yang tidak terlihat secara jelas pada frame terpilih tidak akan dianalisis. Oleh karena itu, fitur ini berfungsi sebagai pengujian masukan video sederhana dan belum dapat disebut sebagai deteksi video secara real-time atau frame-by-frame.

Pada Gambar 4.11, video belum diunggah sehingga halaman masih menampilkan pesan “Pilih video untuk memulai deteksi”. Tampilan tersebut menunjukkan bahwa sistem telah menyediakan komponen masukan video, tetapi proses inferensi baru dijalankan setelah pengguna memilih berkas.



Gambar 4. 12 Fitur kamera visual secara *real-time*

Gambar 4.12 menunjukkan halaman Deteksi Kamera yang memungkinkan pengguna mengambil satu foto secara langsung menggunakan webcam atau kamera perangkat. Ketika halaman dibuka, aplikasi meminta izin untuk mengakses kamera. Setelah izin diberikan, pengguna dapat mengarahkan kamera ke area kulit dan mengambil foto.

Foto yang diambil melalui kamera digunakan sebagai satu citra masukan. Aplikasi mengubah citra ke format RGB, kemudian mengirimkannya ke model YOLOv8. Model memproses citra dan menghasilkan bounding box, kelas jerawat, serta confidence. Hasil deteksi selanjutnya ditampilkan setelah proses pengambilan foto selesai.

Area berwarna hitam pada Gambar 4.12 merupakan bagian pratinjau kamera ketika citra belum berhasil ditampilkan atau belum diambil. Kondisi tersebut dapat terjadi karena kamera belum memperoleh izin akses, perangkat kamera belum aktif, atau pengguna belum menekan tombol pengambilan foto.

Fitur ini belum melakukan inferensi secara terus-menerus terhadap setiap frame kamera. Sistem hanya mengambil satu foto dari webcam dan menganalisis foto tersebut. Oleh karena itu, istilah yang lebih tepat adalah “pengambilan citra melalui kamera”, bukan “deteksi kamera secara real-time”. Deteksi real-time baru dapat

dinyatakan apabila aplikasi memproses frame video dari kamera secara berkelanjutan dan memperbarui bounding box secara langsung.

Informasi keluaran aplikasi mencakup jumlah objek, kelas hasil prediksi, dan confidence. Pengujian aplikasi sebelumnya menunjukkan bahwa sebagian citra dapat terdeteksi, sedangkan sebagian lainnya menghasilkan nol objek atau bounding box pada area yang tidak sesuai. Kondisi tersebut bukan disebabkan oleh Streamlit, melainkan oleh keluaran model dan pemilihan threshold. Oleh sebab itu, hasil deployment harus dianalisis bersama metrik validasi dan data uji, bukan hanya berdasarkan tampilan satu citra.

Sistem ini berfungsi sebagai alat bantu deteksi dan klasifikasi objek pada citra serta tidak digunakan sebagai alat diagnosis medis atau penentu tingkat keparahan. Informasi hasil deteksi perlu ditampilkan sebagai prediksi model agar pengguna memahami keterbatasan sistem.

BAB V
PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan pada bab sebelumnya, kesimpulan penelitian dapat dirumuskan sebagai berikut:

1. Penelitian berhasil membangun sistem deteksi objek berbasis YOLOv8s untuk mengidentifikasi lima kelas jerawat, yaitu Jerawat Blackheads, nodules, papula, pustula, dan whitehead. Model dilatih menggunakan transfer learning dari bobot yolov8s.pt dengan ukuran citra 640 × 640 piksel, batch size 16, dan patience 20.
2. Berdasarkan 11 hasil eksperimen yang telah tersedia, konfigurasi rasio 80:15:5 dengan maksimum 120 epoch menghasilkan nilai mAP@0.5:0.95 tertinggi sebesar 0,363 sehingga menjadi model terbaik sementara. Pelatihan berhenti pada epoch ke-96 melalui early stopping, sedangkan bobot best.pt diperoleh dari epoch terbaik ke-76.
3. Model terbaik memperoleh precision 0,414, recall 0,533, mAP@0.5 sebesar 0,485, dan mAP@0.5:0.95 sebesar 0,363. Nilai recall yang lebih tinggi daripada precision menunjukkan bahwa model lebih kuat dalam menemukan objek target, tetapi masih berpotensi menghasilkan false positive. Selisih antara mAP@0.5 dan mAP@0.5:0.95 juga menunjukkan bahwa ketepatan posisi bounding box masih dapat ditingkatkan.
4. Bobot best.pt telah diimplementasikan pada aplikasi berbasis Streamlit yang dapat dijalankan secara lokal melalui peramban. Aplikasi menyediakan fitur deteksi gambar, analisis frame representatif dari video, dan pengambilan foto melalui kamera, serta menampilkan bounding box, kelas prediksi, dan nilai confidence.
5. Kemampuan deteksi model dipengaruhi oleh jumlah dan keseimbangan data, ketepatan anotasi, pencahayaan, resolusi, jarak pengambilan gambar,

serta kemiripan citra baru dengan data pelatihan. Oleh karena itu, sistem digunakan sebagai keluaran penelitian dan alat bantu klasifikasi, bukan sebagai alat diagnosis medis atau penentu tingkat keparahan.

5.2 Saran

Berdasarkan hasil dan keterbatasan penelitian, beberapa saran yang dapat digunakan untuk pengembangan selanjutnya adalah sebagai berikut:

1. Menambah jumlah dan keragaman citra pada setiap kelas, menyeimbangkan jumlah instance, memeriksa kembali ketepatan bounding box, serta melibatkan ahli yang relevan dalam verifikasi label untuk mengurangi kesalahan anotasi dan meningkatkan kemampuan generalisasi model.
2. Melakukan evaluasi akhir menggunakan data test yang benar-benar terpisah dengan confusion matrix, confusion matrix ternormalisasi, kurva Precision-Confidence, Recall-Confidence, F1-Confidence, dan Precision-Recall. Threshold confidence aplikasi sebaiknya dipilih berdasarkan titik terbaik pada kurva F1 dan diverifikasi pada data uji.
3. Melakukan pengujian generalisasi pada lebih banyak citra baru dengan kondisi pencahayaan, resolusi, sudut, jarak, dan latar yang beragam. Hasil pengujian perlu dicatat dalam bentuk jumlah deteksi benar, false positive, dan false negative agar performa sistem tidak hanya dinilai dari satu contoh citra.
4. Mengembangkan deployment dengan pemrosesan video per frame atau streaming kamera real-time, pengujian waktu inferensi pada CPU dan GPU, serta penanganan kesalahan saat model atau berkas masukan tidak dapat dibaca. Pengembangan tersebut perlu tetap mempertahankan informasi bahwa hasil aplikasi merupakan prediksi model.
5. Membandingkan YOLOv8s dengan varian YOLO lain atau pendekatan instance segmentation. Pendekatan segmentasi dapat dipertimbangkan karena objek jerawat berukuran kecil dan memiliki bentuk yang tidak selalu dapat direpresentasikan secara optimal menggunakan bounding box.

DAFTAR PUSTAKA

Asbullah, P. W. (2021). JKA (Jurnal Keperawatan Abdurrab). *FAKTOR-FAKTOR YANG MEMPENGARUHI TERHADAP TIMBULNYA ACNE VULGARIS (JERAWAT) PADA REMAJA DI SMAN 1 PELANGIRAN KABUPATEN INDRAGIRI HILIR TAHUN 2018*, 80.

azmi, N. (2025, April 15). Kenali Perbedaan 11 Jenis Jerawat untuk Perawatan yang Tepat. *Jerawat*.

Dimas, d. E. (2025, Desember 8). Ini 11 Cara Menghilangkan Komedo Hitam di Hidung dengan Cepat. *kecantikan,komedo,perawatan wajah*.

Fadli, d. R. (2024, Juni 3). Jenis-Jenis Jerawat yang Perlu Diketahui dan Cara Mengatasinya. *Jerawat*.

Febrianto, M. R. (2025). Prosiding Seminar Nasional Sains dan Teknologi Seri III. *PEMANFAATANARTIFICIALINTELLIGENCEUNTUKMENGIDENTIFIKASIDAN MENGATASI MASALAH KESEHATAN KULIT WAJAH*, 712.

Krisandryka, D. (2023, Desember 7). Acne Vulgaris. *Epidemiologi Acne Vulgaris*, pp. 5-8.

Muhammad Dafa Maulana, L. N. (2024). e-Proceeding of Engineering : Vol.11. *Evaluasi Kinerja YOLOv8 dalam Identifikasi Kesegaran Ikan dengan Metode Deteksi Objek`*, 2864.

Nava Muzdalifah, K. A. (2020). Youngster Physics Journal. *IDENTIFIKASI JENIS JERAWAT DENGAN WAVELET HAAR DAN JARINGAN SYARAF TIRUAN PROPAGASI BALIK*, 172.

NUR SIFATULLAH, Z. (2021). Prosiding Biologi Achieving the Sustainable Development Goals. *Jerawat (Acne vulgaris): Review Penyakit Infeksi Pada Kulit*, 19.

Puji, A. (2024, Januari 8). Komedo Putih (Whitehead). *Jerawat*.

Qurotul Aini, N. L. (2021). CESS (Journal of Computer Engineering System and Science). *DETEKSI DAN PENGENALAN OBJEK DENGAN MODEL MACHINE LEARNING: MODEL YOLO*, 193.

Retno Try Lestari, L. Z. (2021). Jurnal Farmasi Komunitas Vol. 8, No. 1, (2021. *PERILAKU MAHASISWA TERKAIT CARA MENGATASI*, 16.

Syahallah Chinta W, A. G. (2023). Seminar Nasional 2023. *Dampak Standar Kecantikan Bagi Perempuan di Indonesia*, 1441.

Achmad, Y. F., Yulfitri, A., & Ulum, M. B. (2021). Identifikasi Jenis Jerawat

Berdasarkan Tekstur Menggunakan GLCM dan Backpropagation. *Jurnal SAINTIKOM (Jurnal Sains Manajemen Informatika Dan Komputer)*, *20*(2), 139. https://doi.org/10.53513/jis.v20i2.4747

Akbar, C. A. D., & Pramuningtyas, R. (2024). Efektivitas Penggunaan Zinc pada Acne Vulgaris. *Journal of Comprehensive Science*, *3*(1), 109–116.

Arifianto, J. (n.d.). *Aplikasi Web Pendeteksi Jerawat Pada Wajah Menggunakan Algoritma Deep Learning dengan TensorFlow*.

Artikel, R., Agustin, G. V., & Ayub, M. (2024). *Deteksi dan Klasifikasi Tingkat Keparahan Jerawat : Perbandingan Metode You Only Look Once Acne Severity Detection and Classification : Comparing You Only Look Once Methods*. *10*, 468–481.

Asbullah, Wulandini Putri, & Yulia Febrianita. (2021). Faktor Faktor Yang Mempengaruhi Terhadap Timbulnya Acne Vulgaris Pada Remaja. *Jka*, *04*(September), 78–88.

Aurelia, C. A., Prasetya, D. A., Data, S., Pembangunan, U., Veteran, N., & Timur, J. (2023). *Implementasi Pembelajaran AI Mastery Program dalam Mengembangkan Aplikasi Berbasis Web di PT . Orbit Ventura Indonesia*. *299*, 1–10.

Aziz, F., Bina, U., Informatika, S., Mandiri, U. N., & Wajah, M. (2023). *YOLO-V8 PENINGKATAN ALGORITMA UNTUK DETEKSI*. *7*(3), 1437–1444.

Bidang Kesehatan Fangatulo Dodo Telaumbanua, D., Hulu, P., Zulfiter Nadeak, T., Romeo Lumbantong, R., & Dharma, A. (2019). Penggunaan Machine Learning. *Jurnal Penelitian Teknik Informatika*, *2*, 391.

Cahyanti, M. (2023). *SISTEM PENDETEKSI PLAT NOMOR POLISI KENDARAAN DENGAN ARSITEKTUR YOLOV8*. *27*(2), 753–761. https://doi.org/10.46984/sebatik.v27i2.2374

Fadhillah, N. N. (2026). *Deep Learning-based Multi-Class Acne Detection on Facial Images Using*. *2*(2), 11–20. https://doi.org/10.22266/inassexpress.2026.002

Harlim, A., Setiawan, I., & Harlim, C. (2025). Hubungan Penggunaan dan Penggantian Masker dengan Kejadian Akne Vulgaris Pada Mahasiswa Universitas Kristen Indonesia. *Jurnal Kesehatan Lingkungan Indonesia*, *24*(2), 171–176. https://doi.org/10.14710/jkli.66754

Hidayat, R., & Subekti, A. (2025). *Evaluasi Kinerja Model Machine Learning dalam Cross-Project Defect Prediction Menggunakan Library PyCaret*. 163–176.

Homepage, J., Rizqi Andini, A., Yuadi, I., Pengembangan Sumber Daya Manusia, J., & Sekolah Pascasarjana, F. (2025). *MALCOM: Indonesian Journal of Machine Learning and Computer Science Classification of Acne Type Based*

on Convolutional Neural Network Klasifikasi Jenis Jerawat Berdasarkan Convolutional Neural Network. *5*(1), 301–308.

Ilahiyah, S., & Nilogiri, A. (2000). *Implementasi Deep Learning Pada Identifikasi Jenis Tumbuhan Berdasarkan Citra Daun Menggunakan Convolutional Neural Network*. 49–56.

Listiawan, M. Y., Fajrin, F. M., Rahmadewi, Hidayati, A. N., Sawitri, Indramaya, D. M., Setiabudi, R. J., & Wardiana, M. (2022). Clinical Profile and Treatment of Acne Vulgaris Patients. *Berkala Ilmu Kesehatan Kulit Dan Kelamin*, *34*(3), 156–161. https://doi.org/10.20473/bikk.V34.3.2022.156-161

Marshalia, V. (n.d.). *Perancangan Pemanfaatan IoT dan Machine Learning Untuk Sistem Monitoring Kesehatan Kulit Wajah Berjerawat*. *3*(1), 135–145.

Maulida, Y., & Topik, M. M. (2024). Penanganan Acne Vulgaris Terkini Program Studi Profesi Dokter , Fakultas Kedokteran , Universitas Malikussaleh , Indonesia Departemen Ilmu Penyakit Kulit dan Kelamin , Rumah Sakit Umum Daerah Cut Meutia , The study of the Global Burden of Disease (GBD). *Termometer: Jurnal Ilmiah Ilmu Kesehatan Dan Kedokteran*, *2*(3), 98–111.

Mudin, I., Komputer, I., & Mandiri, U. N. (2026). *Aplikasi Deteksi Dini Penyakit Kulit Wajah Model Python Berbasis Deep Learning Yolo V8*.

Nugroho, P. A., Fenriana, I., Arijanto, R., & Kom, M. (2020). *IMPLEMENTASI DEEP LEARNING MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK (CNN) PADA EKSPRESI MANUSIA*. *1*.

Putranda, A., Kelana, I., Fauziyah, K., Widyasari, S. L., & Islamiah, D. (n.d.). *Perilaku mahasiswa terkait cara mengatasi jerawat*. *8*(1), 15–19.

Putri, V. A., Carissa, K., Sotyawardani, A., & Rafael, R. A. (2023). Peran artificial intelligence dalam proses pembelajaran mahasiswa di Universitas Negeri SurabayaNANo ranking found for "Qalam : Jurnal Ilmu Kependidikan." *Proceeding.Unesa.Ac.Id*, *12*(1), 66–73. https://proceeding.unesa.ac.id/index.php/sniis/article/download/840/318

Regression, L. (2025). *Evaluasi Model Machine Learning untuk Prediksi Harga Mobil dengan Perbandingan Ensemble dan Regresi Linear*. 129–143.

Roihan, A., Sunarya, P. A., & Rafika, A. S. (2020). Pemanfaatan Machine Learning dalam Berbagai Bidang: Review paper. *IJCIT (Indonesian Journal on Computer and Information Technology)*, *5*(1), 75–82. https://doi.org/10.31294/ijcit.v5i1.7951

Sathyanarayanan, S., & Tantri, B. R. (2024). *Confusion Matrix-Based Performance Evaluation Metrics*. *27*(4).

Sidik, A. D., & Ansawarman, A. (2022). Prediksi Jumlah Kendaraan Bermotor Menggunakan Machine Learning. *Formosa Journal of Multidisciplinary Research*, *1*(3), 559–568. https://doi.org/10.55927/fjmr.v1i3.745

Sifatullah, N., & Zulkarnain. (2021). Jerawat (Acne vulgaris): Review Penyakit Infeksi Pada Kulit. *Prosiding Biologi Achieving the Sustainable Development Goals* , *November*, 19–23. http://journal.uin-alauddin.ac.id/index.php/psb

Sobron, M., & Lubis. (2021). Implementasi Artificial Intelligence Pada System Manufaktur Terpadu. *Seminar Nasional Teknik (SEMNASTEK) UISU*, *4*(1), 1–7. https://jurnal.uisu.ac.id/index.php/semnastek/article/view/4134

Studi, P., Informasi, S., Indonesia, U. P., & Somantri, L. (2025). *Pemetaan mobilitas penduduk di kawasan pinggiran Kota Bandung*. *1790*. https://doi.org/10.22146/mgi.70636

Trenggono, P. H., & Bachtiar, A. (2023). Peran Artificial Intelligence Dalam Pelayanan Kesehatan : a Systematic Review. *Jurnal Ners*, *7*(1), 444–451. https://doi.org/10.31004/jn.v7i1.13612

Yolov, B., & Resnet, D. A. N. (2024). *JUTEKOM Jurnal Teknologi dan Ilmu Komputer*. *01*(03), 2–9.